



RAPPORT DE STAGE

DÉVELOPPEMENT D'UN SYSTÈME DE MESURE DE POLLUTION BASÉ SUR DES CAMÉRAS MULTISPECTRALES

PROJET RÉALISÉ PAR: ILYES SAIS

ENCADRANTS:

SOFIANE MAZEGHRANE (SUEZ - CIRSEE)
THIBAUD MARUEJOULS (SUEZ)
PIERRE LECHEVALLIER (EAWAG)

ANNÉE UNIVERSITAIRE 2023/2024

Remerciements

Je tiens tout d'abord à exprimer ma profonde gratitude envers SUEZ pour avoir accepté de m'accueillir au sein de son établissement pendant ce stage.

Mon immense reconnaissance va à l'ensemble des différents services du département de recherche et développement de SUEZ et du CIRSEE, qui m'ont offert une opportunité exceptionnelle d'apprendre et de contribuer. J'ai pu m'intégrer facilement et enrichir mon expérience au quotidien grâce à votre accueil chaleureux et votre soutien.

Mes remerciements les plus sincères vont à mon tuteur principal et responsable de projet, Monsieur Sofiane Mazeghrane, pour ses précieux conseils et son accompagnement tout au long de ce stage. Votre expertise dans le domaine de la recherche et de l'innovation a été d'une importance capitale dans la réalisation de mes missions.

Un grand merci également à Monsieur Thibaud Maruejols pour ses conseils avisés et son soutien en tant qu'ingénieur R&D et responsable de projet. Votre aide a été précieuse pour comprendre les enjeux techniques et organisationnels de SUEZ.

Je remercie également Pierre Lechevalier, doctorant à l'EAWEG, pour sa collaboration et son support technique dans le cadre du projet de caméra multispectrale.

Je souhaite également remercier les experts du CIRSEE pour leur disponibilité et leur partage de connaissances qui ont enrichi mon expérience et m'ont permis de progresser dans mes travaux.

Enfin, je tiens à remercier mes professeurs de l'Université Paris-Dauphine pour leurs enseignements et leur soutien tout au long de l'année, qui ont préparé le terrain pour ce stage.

Contents

List of Abbreviations	8
Glossaire	9
1 Introduction	10
2 Partie Organisation et Communication	12
2.1 Présentation de l'Organisation	12
2.1.1 Histoire de l'Entreprise Suez et CIRSEE	12
2.1.2 Activité et Caractéristiques Globales	14
2.1.3 Présentation du Service	16
2.2 Analyse de certaines dimensions culturelles et/ou communicationnelles . .	18
2.2.1 Introduction	18
2.2.2 Encadrement et Organisation du Projet	18
2.2.3 Début du Stage et Immersion dans le Domaine	19
2.2.4 Intégration et Gestion de Projet	19
2.2.5 Collaboration à Distance et Outils Utilisés	20
2.2.6 Avancement et Adaptation	20
2.2.7 Observation et Application Pratique	20
2.2.8 Analyse des Dimensions Culturelles	21
2.2.9 Cohérence et Façonnage Réciproque	21
2.2.10 Écarts et Tensions	21
2.2.11 Conclusion	22
2.3 Analyse Approfondie de la Question du Changement	22
2.3.1 Réorganisation du Service	22
2.3.2 Introduction d'un Nouvel Outil Technique : la Caméra Multispectrale	22
2.3.3 Analyse en termes d'apprentissages et de déplacements identitaires	23
2.3.4 Exemples Concrets	23
2.4 Conclusion de la Partie Organisation et Communication	23
3 Partie Informatique	25
3.1 Présentation des Missions Réalisées	25
3.1.1 Résumé des Missions Réalisées	25
3.1.2 Schéma de Conduite de Projet	27
3.2 Description des Missions	28
3.2.1 Mission 1: Lectures sur les thématiques de l'eau usée et l'environnement	28
3.2.2 Mission 2: Configuration du projet sur Visual Studio Code	30
3.2.3 Mission 3: Mise en place et calibration des caméras multispectrales	31

3.2.4	Mission 4: Planification des réunions et coordination avec les en-	
	cadrants	35
3.2.5	Mission 5: Récupération des données images sur le site	36
3.2.6	Mission 6: Construction de la base de données	37
3.2.7	Mission 7: Prétraitement des images par techniques de machine	
	learning	39
3.2.8	Mission 8: Organisation et analyse des données prétraitées	43
3.2.9	Mission 9: Modélisation des Données Organisées	45
3.3	Résultats des Modèles XGBoost	49
3.3.1	Prédictions avec la Caméra 1	50
3.3.2	Prédictions avec la Caméra 2	51
3.3.3	Prédictions avec les Données Combinées des Deux Caméras	52
3.4	Discussion des Résultats pour la Caméra 1	52
3.4.1	Prédiction de la Turbidité	53
3.4.2	Prédiction du MES	53
3.4.3	Prédiction du NH4	53
3.4.4	Prédiction du DOC	53
3.4.5	Prédiction du COD	53
3.4.6	Conclusion	54
3.5	Discussion des Résultats pour la Caméra 2	54
3.5.1	Prédiction de la Turbidité	54
3.5.2	Prédiction du MES	54
3.5.3	Prédiction du NH4	54
3.5.4	Prédiction du DOC	54
3.5.5	Prédiction du COD	55
3.5.6	Conclusion	55
3.6	Discussion des Résultats pour les Caméras 1 et 2	55
3.6.1	Prédiction de la Turbidité	55
3.6.2	Prédiction du MES	55
3.6.3	Prédiction du NH4	55
3.6.4	Prédiction du DOC	56
3.6.5	Prédiction du COD	56
3.6.6	Conclusion	56
3.7	Utilisation de MLflow pour le Suivi des Expériences:	56
3.8	Conclusion de la Partie Informatique	57
4	Conclusion	58
	Bibliography	59
	Annexes	60

List of Figures

2.1	<i>Canal de Suez. Image source: Cathy Lafon. Source: https://www.sudouest.fr/archives/canal-de-suez-son-histoire-n-a-rien-d-un-long-fleuve-tr.php. Used with permission or under fair use.</i>	12
2.2	<i>Ferdinand de Lesseps. Image source: Hulton Archive/Getty. Source: https://encrypted-tbn1.gstatic.com/licensed-image?q=tbn:ANd9GcTd5WAEc1mLL29Mb6xBtLdpdmgR1M. Used with permission or under fair use.</i>	13
2.3	<i>Jean-Louis Chaussade. Image source: Denis Félix. Source: https://www.initiativesfleuves.org/actualites/jean-louis-chaussade-nouvel-administra. Used with permission or under fair use.</i>	14
2.4	<i>Sabrina Soussan. Image source: JOEL SAGET. Source: https://www.lejdd.fr/societe/sabrina-soussan-pdg-de-suez-faisons-de-nos-dechets-une-sour. Used with permission or under fair use.</i>	14
2.5	Structure du Département Process Epuration sous l'autorité du Responsable Cluster Wastewater Biology	16
2.6	Domaines d'expertise et plateformes du CIRSEE. <i>Image source: SUEZ. Source: https://www.suez.fr/-/media/suez-fr/files/cirsee.pdf. Used with permission or under fair use.</i>	17
2.7	Gestion de projet et planification des missions sur Trello	19
2.8	Planning des réunions hebdomadaires pour le mois de juillet	20
2.9	Installation des caméras multispectrales et de l'ordinateur dans le bungalow	21
3.1	Pourcentage des missions réalisées de 22/05 à 09/08	27
3.2	Diagramme de Gantt des missions réalisées	27
3.3	Structure des dossiers dans Visual Studio Code	31
3.4	Schéma d'installation des caméras et de la lampe halogène	32
3.5	Installation des caméras dans la station d'épuration	32
3.6	Réglages effectués dans le logiciel Colorshadeslab	33
3.7	Whitereference capturée par Caméra 1 avec un temps d'exposition de 1 ms	34
3.8	Whitereference capturée par Caméra 2 avec un temps d'exposition de 1 ms	34
3.9	Prise d'images et configuration des paramètres	35
3.10	Capture d'écran de la plateforme SwitchDrive utilisée pour le partage des images et des résultats	36
3.11	Structure de la base de données créée pour les images et les données de pollution	37
3.12	Interface de l'application de suivi des expériences	38
3.13	Représentation d'un data cube Multispectral. <i>Image source: ResearchGate. © [Author/ResearchGate].</i>	39
3.14	Image capturée par la Caméra 1	40

3.15	Image capturée par la Caméra 2	40
3.16	Extraction du spectre pour une image sur la caméra 1	41
3.17	Extraction du spectre pour une image sur la caméra 2	41
3.18	Application de masques sur l'image de la caméra 1	42
3.19	Application de masques sur l'image de la caméra 2	42
3.20	Moyenne et écart type des spectres pour la caméra 1	42
3.21	Moyenne et écart type des spectres pour la caméra 2	42
3.22	Moyenne des spectres fusionnés de 20 images de la caméra 1 et 2	43
3.23	Moyenne des spectres normalisés fusionnés de 20 images de la caméra 1 et 2	43
3.24	Exemple de DataFrame combinée avec les spectres de la Caméra 1, fusionnée avec la variable de pollution turbidity . Chaque colonne représente une longueur d'onde spécifique, et la colonne turbidity est utilisée comme variable cible pour la modélisation.	43
3.25	Résultats de la prédiction de la turbidité par XGBoost avec les paramètres optimisés.	48
3.26	Prédiction de la Turbidité avec la Caméra 1	50
3.27	Prédiction du MES avec la Caméra 1	50
3.28	Prédiction du NH4 avec la Caméra 1	50
3.29	Prédiction du DOC avec la Caméra 1	50
3.30	Prédiction du COD avec la Caméra 1	50
3.31	Application de XGBoost sur les Variables de Pollution : Turbidité, MES, NH4, DOC, et COD avec les Résultats de R^2 et RMSE	50
3.32	Prédiction de la Turbidité avec la Caméra 2	51
3.33	Prédiction du MES avec la Caméra 2	51
3.34	Prédiction du NH4 avec la Caméra 2	51
3.35	Prédiction du DOC avec la Caméra 2	51
3.36	Prédiction du COD avec la Caméra 2	51
3.37	Application de XGBoost sur les Variables de Pollution : Turbidité, MES, NH4, DOC, et COD avec les Résultats de R^2 et RMSE	51
3.38	Prédiction de la Turbidité avec les Deux Caméras	52
3.39	Prédiction du MES avec les Deux Caméras	52
3.40	Prédiction du NH4 avec les Deux Caméras	52
3.41	Prédiction du DOC avec les Deux Caméras	52
3.42	Prédiction du COD avec les Deux Caméras	52
3.43	Application de XGBoost sur les Variables de Pollution : Turbidité, MES, NH4, DOC, et COD avec les Résultats de R^2 et RMSE	52
4.1	Illustration du flux de travail avec MLflow	61
4.2	Illustration des différences entre imagerie multispectrale et hyperspectrale	62
4.3	Caméra CMS-C avec spectre de transmission des filtres typiques.	63
4.4	Caméra CMS-S avec spectre de transmission des filtres typiques.	64

List of Tables

2.2	Comparaison des secteurs d'activité et des chiffres d'affaires de Suez et Veolia	18
2.3	Évaluation comparative des critères de satisfaction entre Suez et Veolia . .	18
3.1	Réglages des caméras dans le logiciel Colorshadeslab	33

List of Abbreviations

Abbreviation	Definition
COD	Chemical oxygen demand
DCO	Demande chimique en oxygène
DOC	Dissolved organic carbon
HSI	Hyperspectral imaging
MAPE	Mean absolute percentage error
NH ₄ -N	Ammonium
NIR	Near infrared
NTU	Nephelometric turbidity unit
PLS	Partial least squares
PO ₄ -P	Phosphate
RMSE	Root mean square error
RGB	Red blue green
SI	Supplementary information
SO ₄ -S	Sulfate
UV	Ultraviolet
VNIR	Visible near infrared

Glossaire

Terme	Définition
Caméra multispectrale	Une caméra qui capture des données d'image à travers des bandes spectrales spécifiques.
Imagerie hyperspectrale	Une technique d'imagerie qui capture des informations sur une large gamme de longueurs d'onde.
Eau brute	L'eau qui n'a pas encore été traitée ou purifiée.
Eau décantée	L'eau qui a été clarifiée par le processus de décantation pour enlever les particules en suspension.
Spectre de réflectance	La distribution de la réflectance d'un matériau en fonction de la longueur d'onde.
Spectral Python (SPy)	Une bibliothèque Python pour le traitement de données hyperspectrales et multispectrales .
Outliers	Des valeurs de données qui sont nettement différentes des autres observations et peuvent affecter les analyses statistiques.
Lampe halogène	Une lampe à incandescence qui contient un gaz halogène, utilisée souvent dans les sources de lumière pour l'imagerie spectrale.
Hyperparamètre	Un paramètre dont la valeur est définie avant le processus d'entraînement d'un modèle de machine learning et qui contrôle le processus d'apprentissage.
DataFrame	Une structure de données bidimensionnelle, similaire à une table dans une base de données, utilisée en programmation pour manipuler et analyser des ensembles de données.

Chapter 1

Introduction

Contexte du Stage

Au cœur de mon Master 1 en Informatique, spécialité Décision et Données, à l'Université Paris Dauphine-PSL, j'ai eu l'opportunité d'effectuer mon stage au sein de l'entreprise SUEZ, plus précisément au pôle CIRSEE (Centre de Recherche et d'Innovation de SUEZ Environnement) situé à Vésinet Le Pecq. Ce centre est reconnu internationalement pour son expertise en innovation et en recherche, notamment dans les domaines de l'environnement et des technologies de gestion des ressources.

Présentation du Projet

Mon stage a été axé sur un projet de recherche scientifique en intelligence artificielle et data science, visant au développement d'un système de mesure de pollution basé sur des caméras multispectrales. Ce projet, proposé par le LyRE, le centre d'Innovation et l'Expertise de SUEZ, s'inscrit dans un contexte où l'amélioration de la gestion des réseaux d'assainissement urbain est cruciale. Ces réseaux sont responsables de l'évacuation des eaux usées et pluviales vers les stations de traitement, tout en étant des vecteurs majeurs de polluants tels que les métaux lourds, les microplastiques et les bactéries fécales.

Le principal objectif de ce stage était de progresser dans le développement d'un dispositif optique non invasif permettant de mesurer rapidement et précisément les niveaux de pollution dans les conditions difficiles des eaux usées. Mon travail a consisté à concevoir et mettre en œuvre une série d'expériences de mesures sur un site pilote de SUEZ, installé en entrée de la station d'épuration de Carré de Réunion, en région parisienne. J'ai également été chargé de l'exploitation des données spectrales obtenues, en utilisant des algorithmes d'interprétation et de corrélation programmés en Python.

Encadrement et Collaboration

Durant ce projet, j'ai été encadré par Monsieur Sofiane Mazeghrane, Research Project Manager et responsable de projet chez SUEZ, au poste d'Ingénieur Bioprocédés Effluents Résiduels. J'ai également bénéficié du soutien de Monsieur Thibaud Maruejols, ingénieur R&D chez SUEZ, et de Monsieur Pierre Lechevallier, doctorant à l'Eawag. Cette collaboration m'a permis d'acquérir une expérience précieuse et d'approfondir mes connaissances

dans le domaine de l'environnement, ainsi que dans les domaines de la data science et du machine learning. De plus, j'ai développé des compétences en organisation et communication dans un cadre professionnel, essentielles pour évoluer dans un environnement de recherche et développement.

Annonce du Plan

Ce rapport est structuré en plusieurs chapitres, couvrant à la fois les aspects techniques et organisationnels du projet. Dans un premier temps, je présenterai l'organisation dans laquelle j'ai effectué mon stage, en détaillant l'histoire de l'entreprise Suez et du CIRSEE, ainsi que leurs activités et caractéristiques globales. Cette présentation sera suivie d'une description du service au sein duquel j'ai évolué.

Ensuite, j'aborderai les aspects organisationnels et communicationnels de mon intégration dans le projet. Cette partie analysera l'encadrement et l'organisation du projet, mes débuts de stage et mon immersion dans le domaine, ainsi que la manière dont les réunions hebdomadaires et les échanges ont été gérés. J'y décrirai aussi la collaboration à distance, les outils utilisés, et l'adaptation progressive aux exigences du projet.

Dans les chapitres suivants, je me concentrerai sur l'analyse approfondie des changements introduits par l'intégration de nouvelles technologies, en particulier la caméra multi-spectrale. J'y explorerai les apprentissages réalisés, les déplacements identitaires observés, ainsi que les exemples concrets de mise en pratique.

Enfin, je conclurai cette partie en offrant une vue d'ensemble sur l'impact des dimensions culturelles et communicationnelles sur le déroulement du projet et en proposant une réflexion sur les écarts et tensions observés.

Après avoir traité ces aspects, je décrirai les missions qui m'ont été confiées et les étapes techniques réalisées pour atteindre les objectifs du projet. Cette section inclura la récupération et l'organisation des données, le prétraitement des images par des techniques de machine learning, et la modélisation des données pour prédire les variables de pollution.

Pour terminer, une partie sera consacrée aux résultats obtenus, où je présenterai les modèles développés et leur performance. Je conclurai par une analyse critique et des propositions pour de futures améliorations du projet, mettant en perspective les enseignements tirés de ce stage, tant sur le plan technique que sur le plan organisationnel et professionnel.

Chapter 2

Partie Organisation et Communication

2.1 Présentation de l'Organisation

2.1.1 Histoire de l'Entreprise Suez et CIRSEE

Historique de Suez

Suez est une multinationale française spécialisée dans la gestion de l'eau et des déchets, avec une histoire remontant à plus de 150 ans. Initialement fondée pour la construction du Canal de Suez, la société a évolué pour devenir un acteur majeur des services environnementaux. Voici quelques dates marquantes :

- **1855** : Fondation de la Compagnie universelle du canal maritime de Suez par Ferdinand de Lesseps, un diplomate et entrepreneur français visionnaire.



Figure 2.1: Canal de Suez. Image source: Cathy Lafon. Source: <https://www.sudouest.fr/archives/canal-de-suez-son-histoire-n-a-rien-d-un-long-fleuve-tranquille-1838006.php>. Used with permission or under fair use.

- **1869** : Inauguration du Canal de Suez, un événement qui a transformé le commerce mondial en raccourcissant les routes maritimes entre l'Europe et l'Asie.
- **1880** : Création de la Lyonnaise des Eaux et de l'Éclairage, qui deviendra plus tard un pilier de Suez.
- **1997** : Fusion entre Lyonnaise des Eaux et la Compagnie financière de Suez, formant Suez Lyonnaise des Eaux, élargissant ainsi les activités de l'entreprise à l'énergie et à l'environnement.

- **2008** : Introduction en bourse de Suez Environnement, après la fusion de Suez avec Gaz de France pour former GDF Suez (maintenant Engie).
- **2015** : Changement de nom pour simplement Suez, renforçant ainsi son identité dans le domaine des services environnementaux.
- **2021** : Veolia lance une OPA sur Suez, aboutissant à une restructuration majeure de l'entreprise.

Historique du CIRSEE

Le Centre International de Recherche sur l'Eau et l'Environnement de Suez (CIRSEE) est une institution phare dédiée à la recherche et à l'innovation dans le domaine de la gestion de l'eau. Fondé en 1990, le CIRSEE est situé à Le Pecq, près de Paris, et se concentre sur les défis globaux de l'eau et des déchets. Le centre a connu plusieurs expansions pour inclure des projets sur la qualité de l'eau, la valorisation des ressources et la réduction des impacts environnementaux.

Prix et Distinctions

Suez et le CIRSEE ont reçu de nombreuses distinctions pour leur innovation et leur excellence dans la gestion de l'eau et des déchets. Par exemple :

- **2015** : Prix de l'Innovation au Salon des Maires pour un projet de valorisation des biogaz issus des déchets.
- **2019** : Le CIRSEE est récompensé par les Global Water Awards pour ses innovations dans le traitement des eaux usées.

Figures Marquantes

Ferdinand de Lesseps : Fondateur de la Compagnie du canal de Suez, il est reconnu pour sa vision et son rôle crucial dans la réalisation du canal.



Figure 2.2: *Ferdinand de Lesseps.* Image source: *Hulton Archive/Getty.*
Source: https://encrypted-tbn1.gstatic.com/licensed-image?q=tbn:ANd9GcTd5WAEc1mLL29Mb6xBtL7u9QTccQUaa7xVeDPXLUSIrudpzs2WbTIJDdxlNW-beafirc7EdC_dpdmgR1M. Used with permission or under fair use.

Jean-Louis Chaussade : Directeur général de Suez de 2008 à 2019, il a guidé l'entreprise à travers des phases de transformation importantes, notamment l'introduction en bourse.



Figure 2.3: *Jean-Louis Chaussade.* Image source: *Denis Félix.*
Source: *<https://www.initiativesfleuves.org/actualites/jean-louis-chaussade-nouvel-administrateur-diagf/>.* Used with permission or under fair use.

Directrice Actuelle de Suez : Sabrina Soussan, nommée présidente et directrice générale de Suez le 1er août 2022, est une ingénieure franco-allemande avec une longue expérience dans les secteurs de la mobilité, des infrastructures et des services publics. Soussan a pris la tête de Suez avec l'objectif de renforcer les initiatives de développement durable et de transformation numérique de l'entreprise.



Figure 2.4: *Sabrina Soussan.* Image source: *JOEL SAGET.*
Source: *<https://www.lejdd.fr/societe/sabrina-soussan-pdg-de-suez-faisons-de-nos-dechets-une-source-denergie-renouvelable>.* Used with permission or under fair use.

2.1.2 Activité et Caractéristiques Globales

Activité

Suez est organisé en plusieurs pôles d'expertise en France, chacun jouant un rôle clé dans l'offre de services de l'entreprise :

- **Suez Eau France** : Spécialisé dans la distribution d'eau potable et les services d'assainissement pour les collectivités locales et les industriels. Ce pôle se concentre sur :
 - Les études et la modélisation des ressources souterraines.
 - Le captage, le traitement et la distribution d'eau.

-
- La maintenance des réseaux.
 - La collecte et l'épuration des eaux domestiques et industrielles.
 - La valorisation biologique et énergétique des boues issues de l'épuration.
 - **Suez Recyclage et Valorisation France** : Focalisé sur la collecte, le tri, le recyclage, la valorisation des déchets, ainsi que la dépollution et la réhabilitation de sites pollués. Ses activités principales incluent :
 - La collecte des déchets de toute nature (excepté les déchets radioactifs et nucléaires) et la propreté urbaine.
 - Le tri et le prétraitement des déchets.
 - Le recyclage, la valorisation matière, biologique et énergétique des déchets valorisables.
 - L'élimination par incinération ou enfouissement des déchets résiduels.
 - La dépollution et la réhabilitation de sites et sols pollués.
 - Le traitement et la valorisation de boues.
 - **Suez Consulting & Engineering** : Offrant des services de conseil en ingénierie pour des projets durables, incluant l'assistance à maîtrise d'ouvrage publique et la maîtrise d'œuvre. Les activités comprennent :
 - La conception et la construction d'usines de production et de traitement d'eau.
 - Des services associés aux collectivités locales et aux industriels, en France et à l'étranger.
 - **Suez Smart Solutions** : Développement de services numériques liés à l'environnement, tels que :
 - Le télérelevé des compteurs d'eau.
 - La gestion des fuites.
 - Les conteneurs de déchets connectés.
 - **Service Cybersécurité** : Protection des infrastructures critiques et des données sensibles contre les cybermenaces.
 - **Service Data** : Analyse des données environnementales pour optimiser la gestion des ressources et améliorer les performances opérationnelles.
 - **Service Développement Web** : Création et maintenance de plateformes numériques pour la gestion en temps réel des services environnementaux et l'interaction avec les clients.
 - **CIRSEE (Centre International de Recherche sur l'Eau et l'Environnement)** : Principal centre de recherche de Suez, situé au Pecq, avec des projets de R&D innovants dans les domaines de l'eau et des déchets.

2.1.3 Présentation du Service

Organisation du CIRSEE

Le Centre International de Recherche sur l'Eau et l'Environnement de Suez (CIRSEE) est un centre de recherche et d'innovation de premier plan. Il est structuré en différents pôles et départements, chacun avec des responsabilités spécifiques dans les domaines de l'eau, des déchets et de l'environnement. La Figure 2.5 présente un aperçu détaillé de l'organisation, notamment la structure du Département Process Epuration sous l'autorité du Responsable Cluster Wastewater Biology.

Hiérarchie et Responsabilités

Autorité	Équipe	Entreprise
Directrice Générale de Suez	Sabrina Soussan : Présidente-Directrice générale	SUEZ
Directeur de l'Innovation	Jerome Bailly : SVP Innovation	SUEZ - La Défense
Directeur du CIRSEE	Gilles Boulanger : Directeur du CIRSEE	SUEZ - CIRSEE




Figure 2.5: Structure du Département Process Epuration sous l'autorité du Responsable Cluster Wastewater Biology

Fonctionnement et Rôle des Laboratoires

Le CIRSEE dispose de plusieurs laboratoires et plateformes de recherche où des essais sont effectués à la fois en laboratoire et à grande échelle. Par exemple, certains essais sont réalisés au centre d'épuration des eaux usées de Versailles.

- **Laboratoire de Bioprocédés** : Spécialisé dans le traitement des eaux usées et la production de biogaz.

- **Laboratoire de Chimie de l'Eau** : Conduit des recherches sur les traitements physico-chimiques pour produire de l'eau potable.
- **Laboratoire de Matériaux** : Étudie les interactions entre l'eau et les matériaux pour améliorer les réseaux de distribution.

Projets Innovants et Contributions

Les projets réalisés au CIRSEE incluent des innovations majeures dans les domaines de l'eau et des déchets. Voici quelques exemples :

- **MEMlab** : Amélioration des performances des membranes pour les traitements de l'eau.
- **BIOPROCESSlab** : Développement de procédés biologiques avancés.
- **PLASTlab** : Recherche sur les matières plastiques et recyclage.
- **TREATlab** : Innovation dans les traitements d'eau potable.
- **PIPElab** : Étude des interactions eau-matériaux.

Ces projets illustrent l'engagement de Suez et du CIRSEE dans la recherche et l'innovation pour répondre aux défis environnementaux mondiaux. La Figure 2.6 montre les domaines d'expertise et les plateformes du CIRSEE, soulignant les efforts déployés pour innover dans le secteur de l'environnement.



Figure 2.6: Domaines d'expertise et plateformes du CIRSEE. Image source: SUEZ. Source: <https://www.suez.fr/-/media/suez-fr/files/cirsee.pdf>. Used with permission or under fair use.

Comparaison avec Veolia

Table 2.2: Comparaison des secteurs d'activité et des chiffres d'affaires de Suez et Veolia

Entreprise	Secteur	Chiffre d'affaires (EUR)
Suez	Énergie et exploitation des ressources	9 Mrd
Veolia	Énergie et infrastructures	28,5 Mrd

Table 2.3: Évaluation comparative des critères de satisfaction entre Suez et Veolia

Critère	Suez	Veolia
Note Globale	3.4	3.4
Équilibre vie privée/professionnelle	3.4	3.4
Avantages	3.3	3.3
Sécurité de l'emploi et évolution	3.0	3.1
Direction	3.0	3.0
Culture d'entreprise	3.2	3.2
Satisfaction vis-à-vis du salaire	58% des personnes pensent que leur salaire est correct chez Suez	58% des personnes pensent que leur salaire est correct chez Veolia

2.2 Analyse de certaines dimensions culturelles et/ou communicationnelles

2.2.1 Introduction

Dans cette section, nous analyserons en détail les valeurs observables au sein de l'équipe de recherche de CIRSEE, une filiale de SUEZ, et leur adéquation avec la culture d'entreprise plus large de SUEZ. Nous examinerons comment ces valeurs sont mises en œuvre quotidiennement et en quoi elles reflètent ou divergent des valeurs proclamées par l'entreprise. Cette analyse s'appuiera sur mes observations personnelles, des entretiens avec les membres de l'organisation, ainsi que sur des documents internes et externes de communication.

2.2.2 Encadrement et Organisation du Projet

Je suis encadrée par trois personnes : Sofiane Mazeghrane, mon tuteur principal qui travaille à CIRSEE, Thibaud Maruejols, un ingénieur en recherche et développement à SUEZ à Bordeaux, et un doctorant d'EAWEG spécialisé en surveillance sans contact des

eaux usées. Ce projet de caméra multispectrale est réalisé en collaboration avec EAWEG en Suisse, l'Institut Fédéral Suisse des Sciences et Technologies.

2.2.3 Début du Stage et Immersion dans le Domaine

Au début de mon stage, n'ayant pas une connaissance approfondie du domaine de l'environnement, j'ai lu de nombreux articles publiés par Sofiane Mazeghrane et discuté avec des experts de SUEZ pour obtenir des informations. Ces interactions m'ont permis de découvrir beaucoup de choses avec les équipes de CIRSEE. Mon tuteur m'a expliqué le fonctionnement de SUEZ dès le début du stage, m'a fait visiter tous les laboratoires et plateformes, et m'a présenté chaque équipe. Grâce à cela, j'ai pu connaître toutes les personnes qui y travaillent et développer mon réseau.

2.2.4 Intégration et Gestion de Projet

Une fois familiarisée avec l'organisation, j'ai tenté d'intégrer l'idée de mettre en œuvre des données et de l'IA avec les eaux usées. Chaque fin de semaine, j'avais des missions à réaliser et j'utilisais Trello pour planifier mon programme et les tâches à accomplir avant la fin de la semaine. Les deux premières semaines ont été consacrées à la compréhension du sujet du projet et des eaux usées. La Figure 2.7 illustre comment Trello a été utilisé pour organiser et suivre les différentes missions tout au long du projet.

Tâche	Statut	Échéancier	Ligne de...	Depend de
Prétraitement des images	Fait	1 - 16 juil.	1 - 16 juil.	Lectures sur les thé... Configuration du pro... Planification des réu... Récupération de
Construction de la base de données	Fait	11 - 28 juil.	11 - 28 juil.	Récupération des do...
Lectures sur les thématiques de l'eau usée et l'environnement	Fait	22 - 28 mai	22 - 28 mai	
Configuration du projet sur Visual Studio Code	Fait	29 - 31 mai	29 - 31 mai	
Récupération des données	Fait	10 juin - 9...	10 juin - 9 sept.	
Planification des réunions	Fait	5 juil. - 13...	5 juil. - 13 sept.	
Analyse des données	Fait	17 - 26 juil.	17 - 26 juil.	Prétraitement des im...
Modélisation des données	En cours	29 juil. - 30 ao...	29 juil. - 30 ao...	Prétraitement des im... Analyse des données
Déploiement d'un modèle	Pas commencé	2 - 13 sept.	2 - 13 sept.	Modélisation des do...
+ Ajouter tâche				

Figure 2.7: Gestion de projet et planification des missions sur Trello

Réunions Hebdomadaires et Échanges

Chaque semaine, j'avais presque trois réunions : une avec Sofiane Mazeghrane en face à face pour vérifier ma compréhension du projet et mon avancement, une sur Teams avec Pierre Lechevalier pour partager les résultats de chaque tâche, et une réunion principale et générale sur Teams en fin de semaine avec Sofiane, Pierre et Thibaud. Ces réunions étaient cruciales pour suivre l'avancement du projet, planifier les tâches à venir et résoudre les problèmes rencontrés. La Figure 2.8 montre le planning des réunions hebdomadaires pour le mois de juillet.




Figure 2.8: Planning des réunions hebdomadaires pour le mois de juillet

2.2.5 Collaboration à Distance et Outils Utilisés

Pierre Lechevalier, résidant en Australie, faisait sa thèse là-bas. Toutes les réunions avec lui se faisaient sur Teams en raison du grand décalage horaire entre la France et l’Australie. Pour partager le code et les données, nous utilisions SwitchDrive, une plateforme avec une mémoire très grande et un partage illimité avec accès privé. Nous communiquions également via Outlook, où Pierre me donnait des commentaires sur les tâches réalisées et nous planifions les réunions en fonction de sa disponibilité.

2.2.6 Avancement et Adaptation

Après trois semaines, je m’étais bien adaptée à l’entreprise et à mon plan de travail. J’avancais beaucoup dans le projet et avais même des communications extérieures avec une ingénieure en logiciels de l’entreprise SILIOS Technologies, à qui Sofiane avait acheté les caméras multispectrales. J’ai structuré toutes les informations, installé les packages nécessaires sur Visual Studio Code, et lu le manuel sur les caméras et le fonctionnement du logiciel pour l’acquisition des images.

2.2.7 Observation et Application Pratique

Sofiane m’a emmené à la station d’épuration où se trouvait le projet. Dans un bungalow, nous avons installé les deux caméras multispectrales avec un ordinateur spécial pour le logiciel. Cette zone, où nous travaillons à grande échelle, traite toutes les eaux usées. Avant cela, Sofiane avait conçu une structure hydraulique pour récupérer l’eau usée et la faire passer dans le bungalow pour être capturée par les caméras. La Figure 2.9 montre l’installation des caméras multispectrales et de l’ordinateur dans le bungalow.



Figure 2.9: Installation des caméras multispectrales et de l'ordinateur dans le bungalow

2.2.8 Analyse des Dimensions Culturelles

En s'appuyant sur les travaux de Cuche (2016)[1], nous distinguons entre la culture d'entreprise (valeurs officielles de SUEZ) et la culture au sein de l'entreprise (pratiques réelles des employés). Cette distinction permet de mieux comprendre les dynamiques internes et de proposer des améliorations potentielles. Par exemple, pour réduire l'empreinte environnementale, une transition vers des réunions sans papier pourrait être envisagée.

2.2.9 Cohérence et Façonnage Réciproque

SUEZ met en avant des valeurs telles que l'innovation, la protection de l'environnement, et la collaboration dans ses communications externes et internes. Mon observation a révélé que ces valeurs sont effectivement intégrées dans le quotidien de l'équipe. Par exemple, l'utilisation de technologies de pointe comme les caméras multispectrales pour surveiller les eaux usées illustre l'engagement de SUEZ envers l'innovation et la protection de l'environnement. En outre, les fréquentes réunions d'équipe et les collaborations inter-équipes démontrent un fort esprit de coopération.

2.2.10 Écarts et Tensions

Cependant, des écarts entre les valeurs proclamées et les pratiques quotidiennes existent. Par exemple, malgré l'accent mis sur la durabilité, j'ai observé que les impressions sur papier restent courantes lors des réunions, ce qui contraste avec les valeurs environnementales affichées. De même, bien que SUEZ promeuve des valeurs de convivialité, cela n'est pas toujours évident dans les interactions quotidiennes, qui peuvent parfois sembler formelles et centrées sur les résultats.

2.2.11 Conclusion

Cette analyse a révélé une relative cohérence entre les valeurs proclamées par SUEZ et les pratiques internes, bien que des écarts subsistent. La reconnaissance de ces écarts et leur rectification peuvent renforcer la cohérence culturelle et améliorer l'efficacité organisationnelle. Il est crucial de continuer à observer et à ajuster ces pratiques pour aligner pleinement les valeurs internes et externes de l'entreprise.

2.3 Analyse Approfondie de la Question du Changement

Les enseignements de sociologie et de communication dispensés en M1 ont souligné l'importance du changement dans le monde de l'entreprise. Cette section montre comment ces enseignements éclairent les changements observés durant mon stage. Nous aborderons la réorganisation du service et l'introduction d'un nouvel outil technique, en nous appuyant sur les concepts étudiés.

2.3.1 Réorganisation du Service

Le service dans lequel j'ai travaillé a récemment subi une réorganisation majeure pour améliorer l'efficacité et l'innovation. Cette réorganisation a impliqué une redistribution des rôles et des responsabilités, ainsi que l'introduction de nouvelles méthodes de travail collaboratif. L'analyse stratégique permet de comprendre les équilibres sociaux entre les acteurs avant et après cette réorganisation.

Avant la Réorganisation

Avant la réorganisation, les tâches étaient souvent cloisonnées, et la communication entre les différentes équipes était limitée. Chaque équipe travaillait de manière relativement indépendante, ce qui entraînait des redondances et des inefficacités.

Après la Réorganisation

La réorganisation a favorisé une approche plus intégrée et collaborative. Les équipes travaillent désormais sur des projets transversaux, ce qui a amélioré la communication et l'efficacité. Les réunions régulières et les outils de gestion de projet comme Trello et SwitchDrive ont joué un rôle crucial dans cette transition.

2.3.2 Introduction d'un Nouvel Outil Technique : la Caméra Multispectrale

L'introduction de la caméra multispectrale est un exemple de processus d'innovation. En suivant les travaux de Norbert Alter (*L'innovation ordinaire*, Paris, PUF, 2013), nous pouvons analyser les différentes séquences de l'innovation :

- **Incitation :** Le besoin d'améliorer la surveillance des eaux usées a incité à l'adoption de cette nouvelle technologie.

-
- **Conflit** : Des résistances initiales ont été observées, principalement dues à la courbe d'apprentissage et aux changements dans les procédures établies.
 - **Institutionnalisation régressive** : Des ajustements ont été faits pour intégrer pleinement l'outil dans les processus existants.

2.3.3 Analyse en termes d'apprentissages et de déplacements identitaires

Le changement a également impliqué des apprentissages et des déplacements identitaires pour les acteurs impliqués. Les employés ont dû intégrer de nouvelles compétences techniques et adopter des nouvelles pratiques de travail. Ces changements ont été influencés par leurs parcours antérieurs, leurs valeurs professionnelles et la nature de leurs relations avec la hiérarchie et les collègues.

2.3.4 Exemples Concrets

- **Formation continue** : Des sessions de formation régulières ont été organisées pour aider les employés à maîtriser les nouvelles technologies.
- **Partage de connaissances** : Les experts techniques ont joué un rôle clé en partageant leurs connaissances et en soutenant leurs collègues moins expérimentés.
- **Renforcement des liens professionnels** : La collaboration accrue a renforcé les relations professionnelles, favorisant un environnement de travail plus cohésif et solidaire.

2.4 Conclusion de la Partie Organisation et Communication

L'analyse approfondie des dimensions culturelles et communicationnelles au sein de l'organisation a révélé plusieurs aspects cruciaux qui seraient restés inaperçus sans cette étude détaillée.

1. **Cohésion et Collaboration Inter-équipes** : L'importance de la cohésion et de la collaboration inter-équipes, souvent non documentée mais essentielle pour le bon fonctionnement de l'entreprise, est devenue évidente. Les interactions quotidiennes et informelles entre les membres des différentes équipes jouent un rôle central dans la réalisation des projets. Par exemple, les discussions spontanées dans les espaces communs ont souvent permis de résoudre des problèmes complexes plus rapidement que lors des réunions formelles.
2. **Paradoxes Entre Valeurs Affichées et Pratiques Quotidiennes** : Cette analyse a permis d'identifier les paradoxes entre les valeurs affichées dans les communications officielles et les pratiques quotidiennes. Un exemple frappant est l'engagement écologique de l'entreprise, mis en avant dans les documents de communication, contrastant avec l'utilisation excessive de papier observée pendant les réunions. Ce décalage souligne l'importance d'une cohérence entre les valeurs proclamées et les actions quotidiennes pour maintenir la crédibilité organisationnelle.

-
3. **Dynamiques de Changement et Adaptation :** Les dynamiques de changement et d'adaptation des employés face à l'introduction de nouvelles technologies et à la réorganisation des services ont également été mises en lumière. L'étude des processus d'apprentissage et de déplacement identitaire a révélé la résilience et la capacité d'innovation des équipes, souvent sous-estimées dans les rapports standards. Par exemple, l'introduction d'outils de gestion de projet numériques comme Trello a non seulement amélioré l'efficacité mais a aussi favorisé l'appropriation rapide des nouvelles méthodes de travail par les employés.
 4. **Importance des Interactions Humaines :** L'analyse a enrichi notre compréhension de la culture d'entreprise en mettant en avant l'importance des interactions humaines et des pratiques informelles. Les échanges informels et les discussions non planifiées jouent un rôle crucial dans la diffusion de l'information et la création d'un environnement de travail collaboratif et innovant. Les équipes qui réussissent le mieux sont celles où ces interactions sont encouragées et valorisées.
 5. **Processus d'Innovation :** L'étude des processus d'innovation, en se basant sur les travaux de Norbert Alter, a montré comment les différentes séquences de l'innovation se manifestent au sein de l'entreprise. Les phases d'incitation, d'appropriation, de conflit et d'institutionnalisation ont été observées, révélant les défis et les opportunités associés à l'introduction de nouvelles technologies. Par exemple, l'appropriation de la caméra multispectrale et du logiciel associé a nécessité une période d'adaptation, suivie de plusieurs itérations pour optimiser son utilisation.
 6. **Apprentissages et Déplacements Identitaires :** Enfin, l'analyse en termes d'apprentissages et de déplacements identitaires a montré comment les acteurs intègrent le changement et lui donnent du sens. Les employés, compte tenu de leurs parcours antérieurs et de leurs valeurs professionnelles, parviennent à trouver une nouvelle identité professionnelle qui inclut les nouvelles compétences et responsabilités associées au changement. Par exemple, le doctorant encadrant le projet a dû non seulement maîtriser de nouvelles compétences techniques mais aussi redéfinir son rôle au sein de l'équipe.

En conclusion, cette analyse a révélé des aspects fondamentaux de la culture et de la communication organisationnelles qui seraient autrement restés cachés. Elle a mis en lumière l'importance de la cohérence entre les valeurs affichées et les pratiques, la résilience des équipes face au changement, et le rôle central des interactions humaines dans le succès des projets. Ces insights sont précieux pour améliorer les pratiques organisationnelles et renforcer la culture d'entreprise.

Chapter 3

Partie Informatique

3.1 Présentation des Missions Réalisées

3.1.1 Résumé des Missions Réalisées

Mission 1: Lectures sur les thématiques de l'eau usée et l'environnement

- **Objectif :** Acquérir une connaissance approfondie des variables de pollution présentes dans l'eau usée et des méthodes de traitement utilisées, notamment celles employées par SUEZ.
- **Durée :** 1 semaine
- **Portée :** Cette mission s'insère dans le cadre global du projet de surveillance et de traitement des eaux usées, permettant une meilleure compréhension des défis environnementaux liés à cette problématique.

Mission 2: Configuration du projet sur Visual Studio Code

- **Objectif :** Mettre en place l'environnement de travail pour l'analyse des données multispectrales, y compris l'installation des packages nécessaires pour le machine learning.
- **Durée :** 3 jours
- **Portée :** Ce travail était essentiel pour structurer le projet en termes de développement et d'analyse des données capturées par les caméras multispectrales.

Mission 3: Mise en place et calibration des caméras multispectrales

- **Objectif :** Installer et calibrer les caméras multispectrales sur le site de la station d'épuration, puis capturer et prétraiter les images.
- **Durée :** 2 semaines
- **Portée :** Cette mission était cruciale pour garantir la précision des images capturées, condition sine qua non pour des analyses fiables.

Mission 4: Planification des réunions et coordination avec les encadrants

-
- **Objectif** : Organiser des réunions régulières pour suivre l'avancement du projet, avec un focus particulier sur la calibration optique.
 - **Durée** : Continue sur toute la durée du projet
 - **Portée** : Cette mission a permis d'assurer une communication efficace entre les différents acteurs du projet, facilitant la prise de décisions techniques.

Mission 5: Récupération des données images sur le site

- **Objectif** : Collecter les images capturées par les caméras et autres données de capteurs sur le site de la station d'épuration.
- **Durée** : Une fois chaque semaine
- **Portée** : La collecte de données sur site est une étape essentielle pour alimenter la base de données en données réelles, nécessaires pour les analyses.

Mission 6: Construction de la base de données

- **Objectif** : Structurer une base de données des images capturées et des mesures des capteurs, en tenant compte d'une tolérance de 5 minutes pour les mesures synchronisées.
- **Durée** : 1 semaine
- **Portée** : La base de données constitue le cœur du projet, où toutes les données seront stockées et prêtes à être analysées.

Mission 7: Prétraitement des images par techniques de machine learning

- **Objectif** : Appliquer des techniques de machine learning pour le prétraitement des images récupérées.
- **Durée** : 3 semaines
- **Portée** : Cette mission permet de transformer les images brutes en données exploitables pour des analyses plus poussées.

Mission 8: Organisation et analyse des données prétraitées

- **Objectif** : Organiser les données après prétraitement et réaliser une analyse préliminaire.
- **Durée** : 1 semaine
- **Portée** : Cette étape vise à tirer des conclusions initiales des données prétraitées, ouvrant la voie à des analyses plus détaillées.

Mission 9: Modélisation des données organisées

- **Objectif** : Effectuer une modélisation des données pour mieux comprendre les interactions entre les différentes variables de pollution.
- **Durée** : 4 semaines
- **Portée** : La modélisation permet de prédire les comportements futurs des variables de pollution, rendant cette mission cruciale pour l'application pratique des résultats.

3.1.2 Schéma de Conduite de Projet

Le schéma de conduite de projet a permis de suivre et de planifier efficacement les différentes missions à accomplir. La Figure 3.1 illustre le pourcentage des missions réalisées entre le 22 mai et le 9 août. Ce suivi a été essentiel pour évaluer l'avancement du projet et identifier les domaines nécessitant plus d'attention.

De plus, un diagramme de Gantt a été utilisé pour visualiser les missions réalisées tout au long du projet. La Figure 3.2 présente ce diagramme, mettant en évidence les différentes étapes et les échéances respectées. Cette représentation a aidé à organiser les tâches de manière chronologique et à s'assurer que les objectifs étaient atteints en temps voulu.




Figure 3.1: Pourcentage des missions réalisées de 22/05 à 09/08




Figure 3.2: Diagramme de Gantt des missions réalisées

3.2 Description des Missions

3.2.1 Mission 1: Lectures sur les thématiques de l'eau usée et l'environnement

Objectif : L'objectif de cette mission était d'acquérir une compréhension solide des enjeux liés à l'eau usée et à son traitement, ainsi que des méthodes innovantes pour surveiller la qualité de l'eau sans contact direct. Cette étape était cruciale pour bien appréhender le contexte du projet et les défis spécifiques à l'utilisation de caméras multispectrales [11].

Entrées et Sorties de la Mission : Les entrées de cette mission comprennent les rapports, articles scientifiques, et manuels techniques liés au traitement des eaux usées et à l'utilisation de capteurs sans contact. Les sorties incluent une meilleure compréhension des processus de traitement de l'eau et une évaluation des avantages des caméras multispectrales par rapport aux capteurs traditionnels.

Réalisation de la Mission : Au cours de cette mission, j'ai étudié divers documents techniques et scientifiques pour comprendre les processus de traitement des eaux usées, tels que le captage, le dégrillage, la décantation primaire, la filtration, et l'ozonation. J'ai également approfondi la compréhension des variables de pollution, à savoir les MES, la turbidité, la DOC, le COD et le NH_4 , ainsi que leurs méthodes de mesure traditionnelles en laboratoire et via Le *spectrolyser*¹. J'ai également examiné comment les caméras multispectrales pourraient être utilisées pour remplacer le spectrolyser et les analyses en laboratoire, en exploitant les spectres de longueurs d'onde capturés par ces caméras pour prédire ces mêmes variables.

Voici les définitions des principaux processus de traitement des eaux usées étudiés :

- **Captage :** Le captage consiste à prélever l'eau usée dans le réseau d'assainissement pour l'acheminer vers la station d'épuration. Cette étape est essentielle pour concentrer les effluents vers un point de traitement.
- **Dégrillage :** Le dégrillage est un processus de prétraitement mécanique qui consiste à retenir les gros débris (comme les feuilles, les plastiques, et les autres matières solides) à l'aide de grilles ou de tamis avant que l'eau n'entre dans les étapes de traitement plus fines.
- **Décantation primaire :** La décantation primaire permet de séparer les matières en suspension plus lourdes de l'eau en les laissant sédimenter au fond d'un bassin. Ce processus réduit la charge polluante organique avant les étapes de traitement biologique.
- **Filtration :** La filtration est une étape où l'eau passe à travers un matériau poreux (comme du sable ou du charbon actif) qui retient les particules fines et certains polluants dissous. Ce processus améliore la clarté de l'eau et la prépare aux traitements chimiques ou biologiques suivants.
- **Ozonation :** L'ozonation est un procédé de désinfection et d'oxydation avancée où de l'ozone (O_3) est injecté dans l'eau pour détruire les bactéries, les virus, et d'autres micro-organismes, ainsi que pour décomposer certains polluants organiques résiduels.

¹Le spectrolyser est un capteur optique utilisé pour mesurer ces variables par analyse spectrophotométrique, fournissant des données en temps réel sans prélèvement d'échantillons.

Les variables de pollution mesurées au cours du projet comprennent :

- **Matières en Suspension** : Les MES désignent les particules solides en suspension dans l'eau qui ne sont pas dissoutes. Elles sont mesurées en laboratoire par filtration et pesée ou par des méthodes optiques comme le spectromètre. Les MES sont un indicateur clé de la turbidité de l'eau.
- **Turbidité** : La turbidité mesure la clarté de l'eau et est directement liée à la concentration de particules en suspension. Elle est souvent mesurée en unités NTU (Nephelometric Turbidity Units) via des capteurs optiques comme le spectromètre, qui détectent la quantité de lumière diffusée par les particules.
- **Demande Chimique en Oxygène** : COD mesure la quantité de dioxygène nécessaire pour oxyder les matières organiques présentes dans l'eau. C'est un indicateur de la pollution organique et est traditionnellement mesuré par titrage chimique ou par analyse spectrophotométrique.
- **Dissolved Organic Carbon** : Le DOC mesure la quantité de carbone organique dissous dans l'eau. C'est un indicateur important de la matière organique présente, particulièrement utile pour évaluer la qualité de l'eau potable et des eaux naturelles. Le DOC est typiquement mesuré par oxydation catalytique à haute température suivie de détection du dioxyde de carbone produit.
- **Ammonium (NH₄)** : L'ammonium est une forme d'azote dissous qui peut indiquer une pollution organique récente. Il est mesuré par des méthodes chimiques (colorimétrie) ou par capteurs spécifiques comme ceux du spectromètre, et sert à évaluer la qualité de l'eau, notamment dans le cadre des rejets d'eaux usées.

L'objectif de ce projet est de remplacer les méthodes traditionnelles de mesure de ces variables par l'utilisation de caméras multispectrales. Les caméras capturent des spectres de longueurs d'onde qui peuvent être analysés pour prédire ces variables. Au départ, les mesures obtenues via le spectromètre seront utilisées pour valider et affiner les modèles prédictifs développés à partir des données de la caméra multispectrale.

État d'Avancement du Projet : Cette mission s'est située dans la phase de spécification du projet, où il était essentiel de comprendre les bases théoriques et les besoins techniques avant de passer à la configuration et au déploiement des technologies de surveillance. En particulier, il était nécessaire de comprendre comment les caméras multispectrales peuvent être utilisées pour surveiller les variables de pollution de l'eau usée.

Apport Personnel : Grâce à cette mission, j'ai pu apporter une meilleure compréhension des défis environnementaux liés au traitement des eaux usées et contribuer à l'orientation stratégique du projet en soulignant l'importance des technologies sans contact comme l'imagerie hyperspectrale. J'ai également pu déterminer comment ces caméras peuvent être intégrées pour mesurer efficacement les variables de pollution, potentiellement remplaçant les méthodes traditionnelles.

Résultats : Cette mission a permis de poser les bases théoriques nécessaires à la mise en œuvre pratique du projet. Elle a également confirmé l'intérêt d'utiliser des caméras multispectrales pour la surveillance de la qualité de l'eau dans des environnements complexes comme les stations d'épuration. Les mesures initiales obtenues à partir du spectromètre serviront de référence pour vérifier la précision des prédictions faites par les caméras

multispectrales. Cela nous permettra d'évaluer la viabilité des caméras comme alternative aux méthodes de mesure actuelles.

3.2.2 Mission 2: Configuration du projet sur Visual Studio Code

Objectif : L'objectif principal de cette mission était de mettre en place un environnement de travail adapté pour le traitement des images multispectrales capturées dans la station d'épuration. Cela incluait l'installation et la configuration des bibliothèques Python nécessaires pour le machine learning et le traitement des données Multispectrales, ainsi que l'organisation du projet de manière structurée dans Visual Studio Code.

Entrées et Sorties de la Mission : Les entrées de cette mission incluent l'installation d'Anaconda pour gérer les environnements Python, Visual Studio Code comme IDE (Integrated Development Environment), ainsi que les bibliothèques Python spécifiques comme Pandas, NumPy, Scikit-learn, et surtout Spectral Python (SPy). Les sorties incluent un environnement de travail complètement fonctionnel, prêt à être utilisé pour le traitement des données multispectrales et le développement d'algorithmes de machine learning.

Réalisation de la Mission : J'ai commencé par télécharger et installer Anaconda, qui m'a permis de gérer facilement les environnements Python et les bibliothèques nécessaires. Ensuite, j'ai configuré Visual Studio Code en tant qu'IDE pour ce projet. J'ai installé plusieurs bibliothèques de machine learning et de traitement de données, telles que Pandas, NumPy, Scikit-learn, et surtout Spectral Python (SPy). SPy est une bibliothèque essentielle pour le traitement des images multispectrales ; elle permet de lire, afficher, manipuler et classer les images capturées par les caméras multispectrales.

L'organisation des fichiers et dossiers dans Visual Studio Code a été soigneusement pensée pour maintenir une structure claire. Les dossiers incluent des répertoires pour les codes sources, les données, les images récupérées, et les jeux de données (datasets) utilisés pour l'entraînement des modèles de machine learning.

État d'Avancement du Projet : Cette mission a été réalisée au début du projet, dans la phase de développement initial. Elle était cruciale pour la suite du travail, car elle a permis de préparer un environnement de travail robuste et bien organisé, facilitant ainsi le développement ultérieur des analyses et des modèles.

Apport Personnel : J'ai apporté une organisation rigoureuse et une configuration technique qui ont permis de rendre le projet plus efficace et structuré. En anticipant les besoins futurs du projet, j'ai installé et configuré toutes les bibliothèques nécessaires, ce qui a permis de gagner du temps dans les étapes ultérieures du projet.

Résultats : Grâce à cette mission, l'environnement de travail est maintenant parfaitement configuré pour le traitement des images Multispectrales, avec toutes les bibliothèques nécessaires installées et prêtes à être utilisées. L'organisation des fichiers et dossiers dans Visual Studio Code facilite la gestion du projet et permet de travailler de manière plus efficace sur les différentes étapes du traitement des données 3.3.




Figure 3.3: Structure des dossiers dans Visual Studio Code

3.2.3 Mission 3: Mise en place et calibration des caméras multispectrales

Objectif : Cette mission avait pour objectif de mettre en place et de calibrer les caméras multispectrales dans la station d'épuration pour capturer des images de haute qualité, nécessaires à l'analyse des variables de pollution dans les eaux usées.

Installation des Caméras :

- **Géométrie :** Les caméras ont été installées par mes soins de manière à ce que l'objectif soit perpendiculaire à la surface de l'eau, pour éviter d'obtenir une image distordue. La distance entre les caméras et la surface de l'eau a été fixée à 70 cm pour couvrir toute la largeur du bac dans le champ de vision 3.5.
- **Illumination :** J'ai personnellement remplacé et installé une lampe halogène de 80W pour générer un spectre lumineux blanc d'intensité suffisante dans les gammes

visible et infrarouge. La source lumineuse a été placée à un angle d'environ 45° par rapport à la surface pour éviter les réflexions directes tout en maximisant l'intensité d'illumination.

- **Note :** Une lampe halogène nécessite environ une heure pour émettre un signal stable.




Figure 3.4: Schéma d'installation des caméras et de la lampe halogène



Figure 3.5: Installation des caméras dans la station d'épuration

Réglages de la Caméra : Les réglages des caméras ont été entièrement effectués par moi-même à l'aide du logiciel Colorshadeslab. J'ai optimisé les paramètres suivants pour assurer une capture d'image de qualité (voir Figure 3.6).




Table 3.1: Réglages des caméras dans le logiciel Colorshadeslab

Figure 3.6: Réglages effectués dans le logiciel Colorshadeslab

Calibration Optique : Bien que le logiciel Colorshadeslab permette d'effectuer une calibration optique, j'ai privilégié une approche manuelle via Python pour garantir la précision des opérations mathématiques appliquées. La calibration optique comprend deux parties :

- **Darkreference :** Une image est capturée avec le cache optique placé sur l'objectif de la caméra pour supprimer le bruit interne.
- **Whitereference :** Une image est capturée à l'aide d'un objet optique de réflexion parfaite Zenith Lite™. Cette référence est essentielle pour normaliser les images en fonction de l'inhomogénéité de l'illumination (voir Figure 3.7 et Figure 3.8)..




Figure 3.7: Whitereference capturée par Caméra 1 avec un temps d'exposition de 1 ms


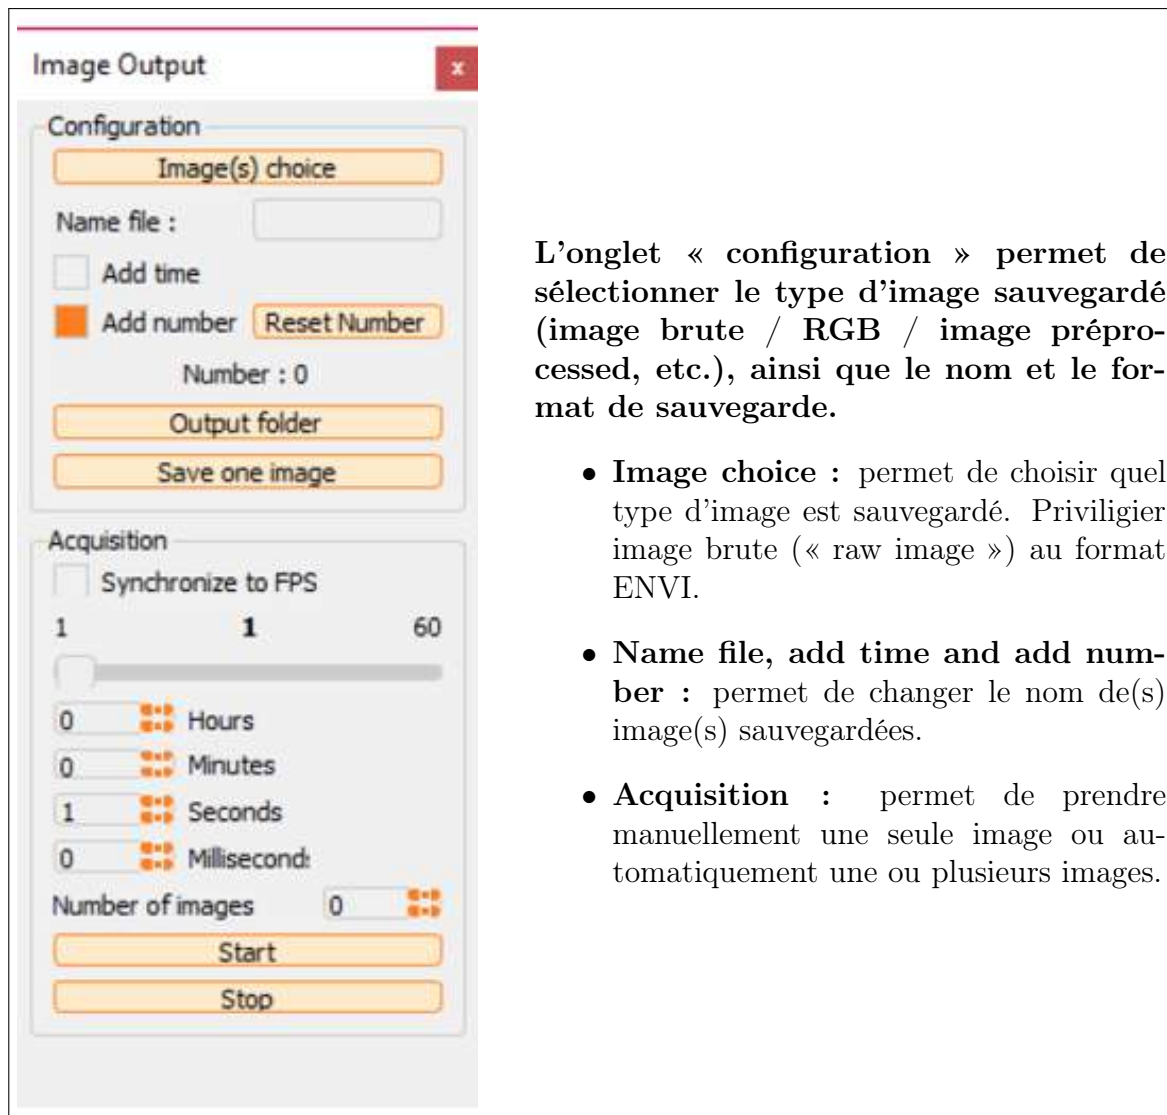


Figure 3.8: Whitereference capturée par Caméra 2 avec un temps d'exposition de 1 ms

Prise d'Images : Dans l'onglet « configuration » du logiciel, différents types d'images peuvent être sauvegardés (brutes, RGB, pré-traitées). Pour ce projet, nous avons privilégié les images brutes (« raw image ») au format ENVI. J'ai personnellement configuré le logiciel pour effectuer une acquisition automatique des images toutes les 5 minutes, synchronisée avec l'acquisition des données des capteurs et du spectromètre (voir Figure 3.9).



L'onglet « configuration » permet de sélectionner le type d'image sauvegardé (image brute / RGB / image préprocessé, etc.), ainsi que le nom et le format de sauvegarde.

- **Image choice** : permet de choisir quel type d'image est sauvegardé. Privilégier image brute (« raw image ») au format ENVI.
- **Name file, add time and add number** : permet de changer le nom de(s) image(s) sauvegardées.
- **Acquisition** : permet de prendre manuellement une seule image ou automatiquement une ou plusieurs images.

Figure 3.9: Prise d'images et configuration des paramètres

3.2.4 Mission 4: Planification des réunions et coordination avec les encadrants

Objectif : L'objectif principal de cette mission était d'assurer une communication efficace avec mes encadrants pour valider les résultats obtenus et continuer à progresser dans le projet. Cette mission incluait la planification des réunions régulières pour discuter des acquisitions d'images, de la qualité des images prises, et de tout ajustement nécessaire dans les réglages des caméras, ainsi que les références white et dark pour la calibration des images.

Coordination et Communication : Les échanges avec mes encadrants se sont principalement faits via Outlook pour la planification des réunions et le partage des résultats intermédiaires. J'ai utilisé la plateforme SwitchDrive pour partager les images capturées, les références de calibration, et les résultats d'analyse avec mes encadrants. Cela nous a permis de collaborer efficacement, même à distance.

- **Réunions régulières** : Les réunions ont été planifiées sur Microsoft Teams, où nous discutons de l'avancement du projet, des résultats des acquisitions d'images, et de

la qualité des images prises. Nous abordions également les éventuelles modifications à apporter aux réglages des caméras et aux références de calibration (white et dark).

- **Partage de documents et d'images :** J'ai partagé les images capturées, les références de calibration, et les résultats d'analyse sur SwitchDrive, un site web sécurisé qui permet de stocker et de partager des fichiers en toute confidentialité. Ce partage nous permettait de visualiser les images et d'analyser les résultats en temps réel, facilitant ainsi les prises de décision.
- **Collaboration sur Outlook :** J'ai utilisé Outlook pour planifier les réunions, échanger des idées avec mes encadrants, et partager des rapports sur les progrès réalisés.

Résultats : Grâce à cette mission, nous avons pu maintenir un flux de communication constant et productif, permettant d'assurer la qualité des images capturées et de prendre rapidement les décisions nécessaires pour ajuster les paramètres de capture et de calibration. Les réunions régulières et les échanges continus ont permis de valider les résultats obtenus à chaque étape du projet, garantissant ainsi une avancée cohérente et efficace (voir Figure 3.10).



Figure 3.10: Capture d'écran de la plateforme SwitchDrive utilisée pour le partage des images et des résultats

3.2.5 Mission 5: Récupération des données images sur le site

Objectif : L'objectif de cette mission était de récupérer les données d'images capturées par les deux caméras multispectrales sur le site de la station d'épuration, de les organiser de manière structurée pour les préparer au prétraitement et à l'analyse.

Processus de Récupération et d'Organisation des Données : Chaque semaine, je me rendais sur le site une fois par semaine pour récupérer les acquisitions d'images des deux caméras, désignées comme Caméra 1 (Cam1) et Caméra 2 (Cam2). Les données étaient stockées dans des fichiers distincts, nommés en fonction de la caméra et de la date d'acquisition. Par exemple, chaque fichier contenait toutes les acquisitions d'images pour une journée spécifique.

Organisation par Type d'Eau : Les données étaient également séparées en fonction du type d'eau capturée : eau brute ou eau décantée. Cette distinction était essentielle pour permettre une analyse comparative des images en fonction de la qualité de l'eau.

Stockage des Données : Après avoir collecté les données, je les ai transférées et organisées sur Visual Studio Code dans le répertoire `exemple_data`. Cette organisation des

Changements et Ajustements : Au cours de cette mission, j'ai initialement travaillé sur des données d'eau décantée durant le mois de juin. Cependant, après un changement de l'éclairage, de nouvelles références ont dû être prises en compte. De plus, Mon encadrant a décidé de se concentrer uniquement sur l'eau brute, ce qui a orienté mes efforts de prétraitement et de modélisation sur les données d'eau brute capturées entre le 11/07 et le 08/08.

référence blanche, chaque image a été normalisée en fonction de son temps d'exposition, une information extraite des fichiers `.hdr`. La normalisation a été réalisée en divisant les valeurs des pixels par le temps d'exposition correspondant. Les fichiers `.bin` ont été utilisés conjointement avec les fichiers `.hdr` pour charger les données brutes des images avant de procéder à la normalisation.

Création d'une Application pour le Suivi des Expériences : En plus de la construction de la base de données principale, j'ai développé une petite application en Python pour enregistrer et suivre les expériences effectuées à la station d'épuration. Cette application permet de documenter chaque visite à la station, en enregistrant des détails tels que :

- Type d'eau (eau brute ou décantée)
- Type de lampe halogène utilisée
- Distance entre la caméra et la surface de l'eau
- Distance entre la lampe et la surface de l'eau
- Fréquence d'acquisition des images

Les informations saisies sont automatiquement ajoutées à la base de données, permettant une gestion rigoureuse des données expérimentales et facilitant l'analyse future (voir Figure 3.12)..




Figure 3.12: Interface de l'application de suivi des expériences

Fusion des Données : Dans le cadre de cette mission, j'ai également fusionné toutes les images avec les données des capteurs, incluant les variables mesurées par le spectromètre telles que le DOC, le NH_4 , la turbidité et les MES. Cette fusion des données a permis de créer deux `DataFrame` finaux, un pour chaque caméra, chacun contenant 2540 lignes après l'analyse et l'élimination des données vides. Les deux `DataFrame` ont maintenant la même taille, facilitant ainsi les analyses comparatives entre les deux ensembles de données.

Résultats : Grâce à cette mission, la base de données est maintenant parfaitement organisée et enrichie de toutes les informations contextuelles nécessaires pour les analyses

ultérieures. Cette organisation minutieuse garantit que toutes les données collectées sont prêtes à être utilisées pour le prétraitement et la modélisation, avec une documentation complète de chaque étape expérimentale.

3.2.7 Mission 7: Prétraitement des images par techniques de machine learning

Objectif : L'objectif de cette mission était de traiter les images multispectrales capturées par les caméras multispectrales en utilisant des techniques de machine learning. Le prétraitement des images est une étape cruciale pour garantir la précision des analyses futures.

Introduction au Data Cube : Les images capturées par les caméras multispectrales sont représentées sous forme de "data cube" tridimensionnel. Chaque data cube a les dimensions suivantes : $423 \times 341 \times 9$, où 423×341 représente la résolution spatiale de l'image (pixels), et 9 représente le nombre de bandes spectrales.

La différence entre les deux caméras réside dans les longueurs d'onde capturées par chacune :

- **Caméra 1 :** Les bandes correspondent aux longueurs d'onde suivantes : 443 nm, 464 nm, 502 nm, 537 nm, 587 nm, 624 nm, 667 nm, 705 nm, et 750 nm.
- **Caméra 2 :** Les bandes correspondent aux longueurs d'onde suivantes : 660 nm, 692 nm, 740 nm, 772 nm, 820 nm, 853 nm, 898 nm, 931 nm, et 1000 nm.




Figure 3.13: Représentation d'un data cube Multispectral. *Image source: ResearchGate.*
© [Author/ResearchGate].

Conversion en Réflectance : Pour normaliser les valeurs des pixels par rapport à la lumière incidente, nous avons converti les images en termes de réflectance. Cette étape est cruciale pour obtenir des mesures précises des propriétés spectrales des surfaces observées. La conversion en réflectance est réalisée à l'aide des références blanche et noire capturées dans la station (voir Figure 3.14 et 3.15).




Figure 3.14: Image capturée par la Caméra 1




Figure 3.15: Image capturée par la Caméra 2

La formule mathématique pour la conversion en réflectance est la suivante :

$$\text{Réflectance} = \frac{\text{Image} - \text{DarkReference}}{\text{WhiteReference} - \text{DarkReference}}$$

Soit $I(i, j, k)$ la valeur du pixel dans l'image originale pour la bande k à la position (i, j) , $D(i, j, k)$ la valeur du pixel pour la DarkReference, et $W(i, j, k)$ la valeur du pixel pour la WhiteReference, la conversion en réflectance se fait par :

$$R(i, j, k) = \frac{I(i, j, k) - D(i, j, k)}{W(i, j, k) - D(i, j, k)}$$

où i et j parcourent les dimensions spatiales, et k parcourt les bandes spectrales.

Recadrage des Images : Après la conversion en réflectance, chaque image est recadrée pour éliminer les bordures non pertinentes et s'assurer que tous les pixels soient de la même dimension que dans la référence blanche.

Extraction du Spectre : L'extraction du spectre est une étape clé pour vérifier la qualité des opérations de prétraitement. Le spectre de chaque pixel est calculé, et les valeurs doivent être comprises entre 0 et 1 pour être valides (voir Figure 3.16 et 3.17) .

La formule mathématique pour calculer le spectre moyen et l'écart-type pour chaque pixel dans l'image est donnée par :

$$\mu(k) = \frac{1}{N} \sum_{i=1}^N S_i(k)$$

$$\sigma(k) = \sqrt{\frac{1}{N} \sum_{i=1}^N (S_i(k) - \mu(k))^2}$$

où $S_i(k)$ est le spectre au point i pour la bande k , $\mu(k)$ est la moyenne des spectres, et $\sigma(k)$ est l'écart-type.




Figure 3.16: Extraction du spectre pour une image sur la caméra 1




Figure 3.17: Extraction du spectre pour une image sur la caméra 2

Application de Masques : Pour isoler les zones d'intérêt dans les images, nous avons appliqué des masques basés sur les percentiles de réflexion. Deux masques ont été créés :

- **Masque du 80ème percentile :** Ce masque sélectionne les pixels dont les valeurs de réflexion sont inférieures au 80ème percentile, éliminant ainsi les artefacts et les zones non pertinentes.
- **Masque du 20ème percentile :** Ce masque sélectionne les pixels dont les valeurs de réflexion sont supérieures au 20ème percentile, éliminant ainsi les zones d'ombre ou de bruit.

Les formules mathématiques pour la création des masques sont les suivantes :

$$M_{80}(i, j) = \begin{cases} 1 & \text{si Réflectance}(i, j) < P_{80} \\ 0 & \text{sinon} \end{cases}$$

$$M_{20}(i, j) = \begin{cases} 1 & \text{si Réflectance}(i, j) > P_{20} \\ 0 & \text{sinon} \end{cases}$$

où P_{80} et P_{20} sont les valeurs des percentiles 80 et 20 de la distribution des réflexions respectivement (voir Figure 3.18 et 3.19).




Figure 3.18: Application de masques sur l'image de la caméra 1




Figure 3.19: Application de masques sur l'image de la caméra 2

Stockage des Résultats : Les spectres extraits pour chaque image, avec et sans l'application de masques, ont été enregistrés dans quatre fichiers CSV distincts :

- Spectre sans masque pour Caméra 1
- Spectre sans masque pour Caméra 2
- Spectre avec masque pour Caméra 1
- Spectre avec masque pour Caméra 2

Tous les fichiers CSV sont indexés par les images ordonnées dans la base de données.




Figure 3.20: Moyenne et écart type des spectres pour la caméra 1




Figure 3.21: Moyenne et écart type des spectres pour la caméra 2

Les spectres des deux caméras ont été fusionnés pour obtenir une vue comparative. Les résultats sont présentés dans les figures suivantes :




Figure 3.22: Moyenne des spectres fusionnés de 20 images de la caméra 1 et 2




Figure 3.23: Moyenne des spectres normalisés fusionnés de 20 images de la caméra 1 et 2

Description des Figures :

- **Figure 3.22** : Cette figure montre la moyenne des spectres obtenus en fusionnant les spectres de 20 images issues des caméras 1 et 2. Les courbes représentent la moyenne des spectres pour chaque caméra, combinées pour obtenir une vue globale des caractéristiques spectrales des images.
- **Figure 3.23** : Cette figure illustre la moyenne des spectres normalisés fusionnés de 20 images des caméras 1 et 2. La normalisation a été appliquée pour ajuster les spectres à une échelle commune, ce qui facilite la comparaison directe entre les spectres des deux caméras.

3.2.8 Mission 8: Organisation et analyse des données prétraitées

Objectif : L'objectif de cette mission était de préparer et d'analyser les données issues des spectres extraits des images multispectrales, afin de les utiliser dans les étapes ultérieures de prétraitement et de modélisation.

Construction de la DataFrame : Une nouvelle DataFrame a été construite en utilisant les spectres extraits comme colonnes (voir Figure 3.24), correspondant aux différentes longueurs d'onde des bandes spectrales. À chaque étape, les données de spectres obtenues pour la Caméra 1 et la Caméra 2 ont été fusionnées (**merge**) pour créer une seule DataFrame combinée. Ensuite, cette DataFrame fusionnée a été enrichie avec une variable de pollution mesurée par des capteurs ou un spectrolyser (comme la turbidité, MES, COD ...etc) qui servira de cible pour les modèles de machine learning à venir.



Figure 3.24: Exemple de DataFrame combinée avec les spectres de la Caméra 1, fusionnée avec la variable de pollution **turbidity**. Chaque colonne représente une longueur d'onde spécifique, et la colonne **turbidity** est utilisée comme variable cible pour la modélisation.

Création de trois DataFrames distinctes : Trois DataFrames différentes ont été créées, chacune correspondant à l'une des variables de pollution ciblées (par exemple, la turbidité, les MES, ou la COD). Ces DataFrames combinent les spectres des deux caméras avec la variable cible, assurant ainsi que toutes les informations nécessaires sont présentes pour l'analyse et la modélisation.

Analyse préalable à la modélisation : Avant de procéder à la modélisation, une analyse approfondie des trois DataFrames obtenues a été réalisée. Cette analyse avait pour but de comprendre la distribution des données, d'identifier d'éventuelles corrélations entre les spectres et les variables de pollution, et de préparer les données pour les étapes de prétraitement et de modélisation. Cette étape a permis de s'assurer que les données étaient bien structurées et prêtes à être utilisées pour les étapes suivantes du projet.

Analyse Exploratoire des Données (Exploratory Data Analysis - EDA) : Avant de passer aux étapes de prétraitement et de modélisation, une analyse exploratoire des données a été réalisée. Cette étape est cruciale pour comprendre la structure des données, identifier les relations entre les variables, et nettoyer les données en éliminant les anomalies ou les variables non pertinentes.

- **Analyse de la forme des données :** La première étape consistait à examiner la structure des données en vérifiant les types de données et en générant un résumé statistique des variables pour obtenir des informations sur les valeurs moyennes, les médianes, les minima et les maxima. De plus, le taux de valeurs manquantes a été évalué pour chaque colonne afin de décider de l'élimination ou de l'imputation des variables concernées.
- **Élimination des colonnes inutiles :** Les colonnes avec un taux élevé de valeurs manquantes (plus de 90%) ont été éliminées pour simplifier l'analyse et éviter les biais dans les résultats.
- **Visualisation initiale des données :** Une matrice de dispersion (Scatter Matrix) a été utilisée pour examiner les relations entre les variables continues. Cette technique permet de visualiser comment les variables sont corrélées entre elles, facilitant ainsi l'identification des relations potentielles à explorer davantage.
- **Histograms des variables continues :** Des histogrammes ont été générés pour les variables continues afin de comprendre leur distribution. Cette étape aide à identifier les distributions normales, les asymétries, ou la présence de valeurs extrêmes (outliers) qui pourraient nécessiter un traitement particulier.
- **Relation entre la variable de pollution et les spectres :** La relation entre les spectres et les variables de pollution a été explorée, par exemple en traçant des graphiques de dispersion pour visualiser comment des longueurs d'onde spécifiques (comme 443 nm) sont corrélées avec la turbidité. Cela permet d'identifier les longueurs d'onde les plus pertinentes pour prédire la variable de pollution.

Conclusion : Cette analyse exploratoire des données a permis de nettoyer et de comprendre la structure des données, préparant ainsi le terrain pour les étapes de prétraitement et de modélisation. Chaque étape a été réalisée dans le but de maximiser la pertinence des données pour les modèles prédictifs à venir, tout en s'assurant que les données étaient suffisamment robustes pour supporter des analyses approfondies.

3.2.9 Mission 9: Modélisation des Données Organisées

Objectif : L'objectif de cette mission est de développer et d'évaluer des modèles prédictifs pour estimer les variables de pollution à partir des spectres extraits des images multispectrales. Un module a été créé pour encapsuler toutes les étapes du prétraitement des données et de la modélisation, permettant ainsi d'automatiser le processus et de faciliter la répétabilité des expériences [10].

Étape 1 : Prétraitement des Données

Avant de procéder à la modélisation, les données ont été soumises à plusieurs étapes de prétraitement pour s'assurer qu'elles étaient prêtes pour l'analyse.

Suppression des Valeurs Aberrantes (Outliers) : Les valeurs aberrantes peuvent biaiser les résultats des modèles. Trois méthodes ont été proposées pour leur suppression:

- **IQR (Interquartile Range) :** Cette méthode élimine les points de données situés en dehors de l'intervalle $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$, où $Q1$ et $Q3$ représentent les premier et troisième quartiles.
- **Z-score :** Les valeurs dont le Z-score est supérieur à un certain seuil (typiquement 3) sont considérées comme des outliers et sont supprimées. Le Z-score est calculé comme suit :

$$Z = \frac{X - \mu}{\sigma}$$

où X est la valeur de la donnée, μ la moyenne, et σ l'écart-type.

- **Isolation Forest :** Cette méthode non-supervisée isole les points aberrants en créant des partitions aléatoires. Les points nécessitant moins de divisions pour être isolés sont considérés comme des outliers.

Normalisation et Mise à l'Échelle : Les données sont ensuite normalisées pour garantir que toutes les caractéristiques contribuent de manière égale à la modélisation. Quatre méthodes ont été proposées :

- **Min-Max Scaling :** Cette technique met à l'échelle les données dans un intervalle donné, généralement $[0, 1]$, selon la formule :

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

où X est la valeur originale, X_{min} et X_{max} sont les valeurs minimum et maximum.

- **Standard Scaling :** Cette méthode standardise les données pour qu'elles aient une moyenne de 0 et un écart-type de 1.
- **L2 Normalization :** Les valeurs sont ajustées de manière à ce que la somme des carrés des valeurs de chaque échantillon soit égale à 1.

Séparation des Données en Ensembles d'Entraînement et de Test : Les données ont été divisées en ensembles d'entraînement et de test en utilisant la méthode de validation croisée K-Fold avec 5 plis. Cette méthode permet de s'assurer que chaque

échantillon est utilisé à la fois pour l'entraînement et pour le test, évitant ainsi les biais de partition et assurant une évaluation plus robuste des modèles.

Plus spécifiquement, chaque pli (ou "fold") a été construit en tenant compte des longueurs d'onde présentes dans la DataFrame, qui représentent les colonnes du spectre de réflectance pour chaque échantillon. Cela signifie que, pour chaque itération de la validation croisée, les données sont divisées en cinq sous-ensembles : quatre sont utilisés pour entraîner le modèle, et le cinquième est utilisé pour évaluer sa performance. Ce processus est répété cinq fois, chaque sous-ensemble servant une fois de jeu de test.

L'objectif de l'utilisation de la validation croisée K-Fold est de maximiser la fiabilité des modèles prédictifs en utilisant efficacement toutes les données disponibles, tout en évitant le surajustement (overfitting). En répartissant les données de manière équilibrée entre les jeux d'entraînement et de test, nous garantissons que les modèles sont testés de manière rigoureuse sur des échantillons variés, offrant ainsi une évaluation plus réaliste de leurs performances. Cette méthode est particulièrement utile lorsque les données disponibles sont limitées, car elle permet d'utiliser chaque échantillon à la fois pour l'entraînement et pour le test, optimisant ainsi l'utilisation des données dans le cadre de la modélisation des variables de pollution. .

Application du PCA : L'analyse en composantes principales (PCA) a été appliquée pour réduire la dimensionnalité des données tout en conservant l'essentiel de la variance. Cela est particulièrement utile lorsqu'il y a beaucoup de variables corrélées. La réduction de dimension a été appliquée principalement sur les spectres combinés des deux caméras.

Cette méthode a été spécifiquement choisie pour la DataFrame combinée des deux caméras car certaines longueurs d'onde, telles que 660 nm et 700 nm, sont communes aux deux dispositifs et présentent des valeurs spectrales similaires. En appliquant le PCA, nous avons pu réduire la redondance causée par ces longueurs d'onde partagées, tout en préservant les caractéristiques essentielles qui influencent les variables de pollution. Cela permet non seulement de simplifier le modèle, mais aussi d'améliorer son efficacité et sa capacité de généralisation en éliminant les informations superflues et en se concentrant sur les composantes principales qui capturent la majorité de la variance présente dans les données.

Étape 2 : Modélisation

Plusieurs modèles de machine learning ont été testés pour prédire les variables de pollution, notamment :

- **PLS Regression (Partial Least Squares) :** La régression PLS est une méthode de régression particulièrement adaptée pour les datasets où les prédicteurs (variables X) sont fortement corrélés. Dans votre cas, les variables prédictives sont les valeurs des spectres de différentes longueurs d'onde capturées par les caméras multispectrales, tandis que la variable de réponse Y représente une variable de pollution telle que la turbidité, le MES ou la COD.

Spécifications de la DataFrame :

- X : Dans votre DataFrame, X correspond aux colonnes représentant les spectres des longueurs d'onde spécifiques . Chaque spectre est une mesure de la réflexion de la lumière à une longueur d'onde donnée, capturée par les caméras 1 et 2.

-
- Y : La variable de réponse Y est une mesure de pollution comme la turbidité, le MES ou COD, DOC. Cette variable est obtenue à partir des mesures du spectromètre ou des capteurs installés sur le site.

Logique de Prédiction avec PLS : Le modèle PLS va projeter les prédicteurs X et la variable de réponse Y sur de nouvelles composantes latentes qui maximisent la covariance entre eux. Cela permet au modèle de capturer les relations complexes entre les longueurs d'onde et les niveaux de pollution. La prédiction finale de la variable de pollution se fait selon la formule suivante :

$$\hat{Y} = XW$$

où :

- X est la matrice des spectres des longueurs d'onde,
 - W est la matrice des poids optimisés par le modèle PLS, calculée pour maximiser la covariance entre les prédicteurs X et la variable cible Y .
- **XGBoost :** XGBoost (Extreme Gradient Boosting) est un modèle de machine learning puissant basé sur le principe du boosting, particulièrement adapté pour des tâches de régression et de classification. Dans ce modèle, plusieurs arbres de décision sont construits séquentiellement. Chaque nouvel arbre est ajusté pour corriger les erreurs des arbres précédents, ce qui permet au modèle d'apprendre progressivement à partir de ses erreurs.

Formule Mathématique et Logique du Modèle : Supposons que $X = [\lambda_1, \lambda_2, \dots, \lambda_n]$ représente les spectres des longueurs d'onde capturées par les caméras multispectrales et que y soit la variable de pollution cible (telle que la turbidité, le MES ou le DOC). XGBoost construit un modèle de prédiction sous la forme d'une somme d'arbres de décision :

$$\hat{y}_i = \sum_{k=1}^K f_k(X_i)$$

où :

- $\hat{y}_i$ est la prédiction pour l'observation i ,
- $f_k(X_i)$ est la prédiction de l'arbre k pour l'entrée X_i ,
- K est le nombre total d'arbres dans le modèle.

Chaque arbre est formé de manière à minimiser une fonction de coût $L(\theta)$, qui intègre à la fois l'erreur de prédiction et un terme de régularisation pour éviter le surapprentissage :

$$L(\theta) = \sum_{i=1}^N l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

où :

- $l(y_i, \hat{y}_i)$ est la fonction de perte (généralement l'erreur quadratique moyenne),
- $\Omega(f_k)$ est un terme de régularisation qui pénalise la complexité du modèle, contrôlant ainsi le surapprentissage.

Optimisation des Hyperparamètres : Les hyperparamètres de XGBoost, tels que le taux d'apprentissage (η), la profondeur des arbres (max_depth), et le nombre d'estimateurs ($n_estimators$), ont été ajustés à l'aide d'une recherche en grille (Grid Search) pour maximiser les performances du modèle. Par exemple, un taux d'apprentissage bas permet au modèle d'apprendre plus lentement mais avec plus de précision, tandis qu'une plus grande profondeur des arbres permet de capturer des interactions complexes entre les longueurs d'onde et les variables de pollution.

Performance de XGBoost : Dans cette étude, XGBoost a surpassé les autres modèles en termes de R^2 (coefficient de détermination) et de RMSE (Root Mean Squared Error), ce qui montre son efficacité pour capturer les relations complexes entre les spectres des longueurs d'onde et les variables de pollution. Les résultats ont montré que ce modèle est particulièrement adapté pour prédire des variables telles que la turbidité, le MES et le DOC, grâce à sa capacité à gérer les interactions non linéaires dans les données (voir Figure 3.25).

```
{'gamma': 0.5, 'learning_rate': 0.1, 'max_depth': 9, 'n_estimators': 300}
Train RMSE: 0.9494654299958325
Test RMSE: 69.37401048624744
Train R²: 0.9999394028888203
Test R²: 0.7108385737362356
Train MAPE: 0.001913092919533139
Test MAPE: 0.14325991925363152
Selected Features: 443, 464, 502, 537, 587, 624, 667, 705
```

Figure 3.25: Résultats de la prédiction de la turbidité par XGBoost avec les paramètres optimisés.

- **SVR (Support Vector Regression) :** Utilise les marges maximales pour la prédiction, particulièrement utile pour des distributions de données complexes.
- **Random Forest :** Un modèle d'ensemble qui construit plusieurs arbres de décision sur des sous-échantillons aléatoires du dataset et agrège les prédictions.
- **Lasso Regression :** Régression linéaire avec régularisation L1 qui sélectionne automatiquement les caractéristiques les plus pertinentes.

Évaluation des Modèles

Les performances des modèles ont été évaluées à l'aide des métriques suivantes :

- **RMSE (Root Mean Squared Error) :**

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

où y_i est la valeur réelle et $\hat{y}_i$ la valeur prédite.

-
- **R² (Coefficient de Détermination)** : Mesure la proportion de la variance de la variable dépendante qui est prédite par les variables indépendantes.
 - **MAPE (Mean Absolute Percentage Error)** :

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Utilisé pour évaluer la précision des prévisions.

3.3 Résultats des Modèles XGBoost

Résultats des Prédictions avec XGBoost : Les figures ci-dessous montrent les performances du modèle XGBoost pour prédire différentes variables de pollution en utilisant les données spectrales des caméras multispectrales. Les résultats sont divisés en trois groupes : prédictions avec les données de la Caméra 1, prédictions avec les données de la Caméra 2, et prédictions avec les données combinées des deux caméras.

3.3.1 Prédiction avec la Caméra 1




Figure 3.26: Prédiction de la Turbidité avec la Caméra 1




Figure 3.27: Prédiction du MES avec la Caméra 1




Figure 3.28: Prédiction du NH4 avec la Caméra 1




Figure 3.29: Prédiction du DOC avec la Caméra 1




Figure 3.30: Prédiction du COD avec la Caméra 1

Figure 3.31: Application de XGBoost sur les Variables de Pollution : Turbidité, MES, NH4, DOC, et COD avec les Résultats de R^2 et RMSE

3.3.2 Prédiction avec la Caméra 2




Figure 3.32: Prédiction de la Turbidité avec la Caméra 2




Figure 3.33: Prédiction du MES avec la Caméra 2




Figure 3.34: Prédiction du NH4 avec la Caméra 2




Figure 3.35: Prédiction du DOC avec la Caméra 2




Figure 3.36: Prédiction du COD avec la Caméra 2

Figure 3.37: Application de XGBoost sur les Variables de Pollution : Turbidité, MES, NH4, DOC, et COD avec les Résultats de R^2 et RMSE

3.3.3 Prédiction avec les Données Combinées des Deux Caméras




Figure 3.38: Prédiction de la Turbidité avec les Deux Caméras




Figure 3.39: Prédiction du MES avec les Deux Caméras




Figure 3.40: Prédiction du NH4 avec les Deux Caméras




Figure 3.41: Prédiction du DOC avec les Deux Caméras




Figure 3.42: Prédiction du COD avec les Deux Caméras

Figure 3.43: Application de XGBoost sur les Variables de Pollution : Turbidité, MES, NH4, DOC, et COD avec les Résultats de R^2 et RMSE

3.4 Discussion des Résultats pour la Caméra 1

Les résultats des modèles de prédiction appliqués aux données capturées par la Caméra 1 sont présentés ci-dessous. Ces résultats mettent en évidence la performance du modèle XGBoost, utilisé pour prédire divers indicateurs de pollution, y compris la Turbidité, le MES, le NH4, le DOC, et le COD.

3.4.1 Prédiction de la Turbidité

La turbidité s'est révélée être une variable prometteuse, en raison de sa relation directe avec l'intensité de la réflexion lumineuse, que les données multispectrales capturent efficacement. Le modèle XGBoost a démontré une forte performance prédictive pour la turbidité, atteignant une valeur R^2 de 0.71 et un RMSE de 69.36 NTU (voir Figure 3.26). Cela indique que le modèle est bien adapté pour estimer la turbidité dans l'eau, en exploitant les données spectrales capturées par la caméra.

3.4.2 Prédiction du MES

La prédiction du MES a également donné des résultats satisfaisants, avec un R^2 de 0.76 et un RMSE de 46.28 mg/L (voir Figure 3.27). La performance suggère que le modèle peut estimer de manière fiable les concentrations de matières en suspension, en utilisant les longueurs d'onde spécifiques les plus sensibles à ces particules. La capacité du modèle à capturer les variations de concentration du MES renforce l'efficacité de l'algorithme XGBoost dans la gestion des relations complexes et non linéaires dans les données.

3.4.3 Prédiction du NH4

Pour l'ammonium, le modèle XGBoost a fourni une performance robuste, atteignant un R^2 de 0.77 et un RMSE de 8.07 mg/L (voir Figure 3.28). Ce niveau de précision est particulièrement remarquable compte tenu des défis associés à la mesure directe du NH4 à l'aide de la spectrophotométrie. Le succès du modèle dans ce domaine suggère que les données spectrales ont fourni des informations cruciales sur les niveaux de concentration de l'ammonium, peut-être par le biais d'associations indirectes avec d'autres composants présents dans l'eau.

3.4.4 Prédiction du DOC

Les prédictions pour le DOC ont également montré les forces du modèle, avec un R^2 de 0.74 et un RMSE de 68.84 mg/L (voir Figure 3.29). Le DOC, un indicateur clé de la pollution organique, a été prédit de manière efficace par le modèle, mettant en évidence sa capacité à gérer la complexité des interactions des composés organiques au sein des eaux usées. Les longueurs d'onde sélectionnées ont probablement fourni des informations cruciales sur la matière organique présente, contribuant à la précision du modèle.

3.4.5 Prédiction du COD

Enfin, les prédictions pour le COD ont affiché un R^2 de 0.79 et un RMSE de 17.51 mg/L (voir Figure 3.30). Le COD est une autre mesure critique de la qualité de l'eau, et la performance du modèle suggère un haut niveau de précision dans l'estimation de cette variable. Les résultats indiquent que les données d'imagerie multispectrale capturées par la Caméra 1, combinées avec le modèle XGBoost, offrent un outil puissant pour le suivi des niveaux de COD dans les eaux usées.

3.4.6 Conclusion

Dans l'ensemble, le modèle XGBoost a démontré de fortes capacités prédictives pour toutes les variables mesurées, avec une précision particulièrement élevée pour la Turbidité et le COD. La performance du modèle souligne la valeur des données d'imagerie multispectrale dans le suivi de la qualité de l'eau et le potentiel de XGBoost en tant qu'outil d'analyse environnementale. Des travaux futurs pourraient explorer davantage l'optimisation des paramètres du modèle et l'extension de cette approche à d'autres indicateurs de pollution ou à d'autres caméras.

3.5 Discussion des Résultats pour la Caméra 2

Les résultats des modèles de prédiction appliqués aux données capturées par la Caméra 2 montrent une performance notable du modèle XGBoost pour diverses variables de pollution. Ces variables incluent la Turbidité, le MES, le NH_4 , le DOC, et le COD.

3.5.1 Prédiction de la Turbidité

La prédiction de la turbidité à l'aide du modèle XGBoost a montré une performance robuste avec un R^2 de 0.83 et un RMSE de 6.56 NTU (voir Figure 3.32). Ce résultat indique que le modèle est particulièrement efficace pour estimer la turbidité en exploitant les données spectrales obtenues par la Caméra 2. La figure correspondante illustre la forte corrélation entre les valeurs prédites et réelles de la turbidité.

3.5.2 Prédiction du MES

Le modèle XGBoost a également bien performé pour la prédiction du MES, avec un R^2 de 0.75 et un RMSE de 42.24 mg/L (voir Figure 3.33). Ce résultat montre que le modèle peut prédire avec précision les concentrations de matières en suspension. Les longueurs d'onde capturées par la Caméra 2 semblent fournir des informations clés permettant au modèle de capturer la complexité de cette variable. La figure associée montre les prédictions du modèle par rapport aux valeurs réelles.

3.5.3 Prédiction du NH_4

Pour l'ammonium, le modèle a atteint un R^2 de 0.74 et un RMSE de 65.87 mg/L (voir Figure 3.34). Bien que ces résultats montrent une bonne performance, ils sont légèrement inférieurs à ceux obtenus pour d'autres variables, ce qui pourrait indiquer une plus grande complexité dans la prédiction des niveaux de NH_4 ou une sensibilité accrue aux conditions spécifiques de l'échantillon. La figure associée montre les prédictions par rapport aux valeurs mesurées de NH_4 .

3.5.4 Prédiction du DOC

La prédiction du DOC a produit un R^2 de 0.59 avec un RMSE de 25.84 mg/L (voir Figure 3.35). Ces résultats indiquent que, bien que le modèle soit capable de capturer une grande partie de la variance des données, il reste une marge d'amélioration, notamment pour affiner la précision des estimations de DOC. Les interactions complexes entre les composés

organiques capturés par les longueurs d'onde de la Caméra 2 pourraient nécessiter des ajustements supplémentaires. La figure associée montre cette relation.

3.5.5 Prédiction du COD

Enfin, la prédiction du COD a montré un R^2 de 0.39 et un RMSE de 124.94 mg/L (voir Figure 3.36), ce qui indique une performance moins robuste du modèle pour cette variable particulière. La précision relativement faible peut être attribuée à des facteurs tels que la complexité du COD ou des variations dans les données d'entrée. Néanmoins, ces résultats fournissent une base pour une optimisation future du modèle. La figure associée montre les résultats de la prédiction du COD.

3.5.6 Conclusion

Les résultats obtenus avec la Caméra 2 confirment que le modèle XGBoost est globalement performant pour la prédiction de la qualité de l'eau, en particulier pour la Turbidité et le MES. Cependant, certaines variables, comme le NH_4 et le COD, présentent des défis plus importants qui pourraient bénéficier d'une optimisation supplémentaire des paramètres du modèle ou de la collecte de données supplémentaires..

3.6 Discussion des Résultats pour les Caméras 1 et 2

Les résultats des modèles de prédiction appliqués aux données combinées capturées par les Caméras 1 et 2 sont présentés ci-dessous. Ces résultats montrent l'efficacité du modèle XGBoost pour prédire divers indicateurs de pollution, y compris la Turbidité, le MES, le NH_4 , le DOC, et le COD, en utilisant les données fusionnées des deux caméras.

3.6.1 Prédiction de la Turbidité

La turbidité est une variable cruciale en raison de sa relation directe avec l'intensité de la réflexion lumineuse. En combinant les données des deux caméras, le modèle XGBoost a affiché une performance améliorée avec un R^2 de 0.79 et un RMSE de 58.34 NTU, comme illustré en Figure 3.38. Cette amélioration suggère que la fusion des données multispectrales des deux caméras enrichit l'information disponible pour le modèle, augmentant ainsi sa précision dans l'estimation de la turbidité.

3.6.2 Prédiction du MES

La prédiction du MES en utilisant les données combinées des deux caméras a montré un R^2 de 0.74 et un RMSE de 88.86 mg/L (Figure 3.39). Cette performance est comparable à celle obtenue avec les données de la Caméra 1 seule, mais montre également l'impact positif de la combinaison des données, qui permet de capturer des variations plus subtiles dans les concentrations de matières en suspension.

3.6.3 Prédiction du NH_4

L'ammonium, un indicateur important de la qualité de l'eau, a été prédit avec un R^2 de 0.80 et un RMSE de 42.90 mg/L, comme illustré en Figure 3.40. Cette performance

est remarquable et met en évidence l'importance de la fusion des données multispectrales pour obtenir une estimation précise des concentrations d'ammonium.

3.6.4 Prédiction du DOC

La prédiction du DOC avec les données combinées a abouti à un R^2 de 0.74 et un RMSE de 9.66 mg/L (Figure 3.41). Cette précision est légèrement supérieure à celle obtenue avec chaque caméra séparément, ce qui montre que la combinaison des données renforce la robustesse du modèle dans l'estimation de la pollution organique.

3.6.5 Prédiction du COD

Enfin, la prédiction du COD à partir des données des deux caméras a montré un R^2 de 0.74 et un RMSE de 17.41 mg/L (Figure 3.42). Ce résultat démontre une fois de plus l'efficacité du modèle XGBoost lorsqu'il est appliqué à des données enrichies provenant de plusieurs sources, ce qui améliore la précision des estimations des niveaux de COD.

3.6.6 Conclusion

Dans l'ensemble, la combinaison des données des deux caméras a permis d'améliorer les performances prédictives du modèle XGBoost pour la plupart des variables de pollution étudiées. La fusion des données d'imagerie multispectrale se révèle être une approche puissante pour le suivi de la qualité de l'eau, augmentant la robustesse et la précision des estimations pour les différentes variables de pollution.

3.7 Utilisation de MLflow pour le Suivi des Expériences:

Objectif : Utiliser MLflow pour enregistrer et suivre les résultats de chaque exécution du modèle, y compris les paramètres, les métriques de performance, et les modèles eux-mêmes.

Résultats et Conclusions

À la fin du processus de modélisation, les résultats obtenus ont permis de comparer les performances des différents modèles en termes de prédiction des variables de pollution. Les modèles ayant les meilleures performances ont été identifiés, et leurs hyperparamètres optimisés ont été enregistrés à l'aide de MLflow pour une future réutilisation.

3.8 Conclusion de la Partie Informatique

Cette partie du rapport a permis de détailler et d'analyser les différentes missions réalisées durant mon stage, en mettant l'accent sur les aspects techniques, les choix méthodologiques, et les résultats obtenus. Le travail accompli a été structuré de manière à progresser logiquement de la collecte de données brutes à leur traitement, leur analyse, et enfin, leur modélisation pour prédire les variables de pollution dans les eaux usées.

D'un point de vue technique, le projet a atteint un degré d'aboutissement satisfaisant, avec des résultats probants dans la majorité des étapes. Les choix technologiques, tels que l'utilisation des caméras multispectrales pour la capture d'images et l'application de techniques de machine learning pour le traitement des données, se sont révélés pertinents et bien adaptés aux objectifs du projet. Cependant, certains défis ont été rencontrés, notamment en ce qui concerne la calibration des caméras et la gestion des références optiques, où des ajustements réguliers ont été nécessaires pour garantir la qualité des données.

Les méthodes employées, telles que la normalisation des données et la sélection de caractéristiques, ont permis d'améliorer la précision des modèles prédictifs, bien que certaines améliorations puissent encore être envisagées. Par exemple, l'intégration d'algorithmes plus avancés ou la combinaison de plusieurs modèles pourrait potentiellement améliorer la précision des prédictions.

En termes d'applicabilité, la solution développée est prometteuse pour une utilisation future dans le domaine du suivi environnemental des eaux usées. Les modèles créés peuvent être utilisés pour surveiller en temps réel la qualité de l'eau dans les stations d'épuration, offrant ainsi une approche non invasive et efficace pour la gestion des ressources en eau.

Pour prolonger ce travail, il serait intéressant d'explorer davantage la robustesse des modèles en les testant sur des jeux de données plus variés ou en intégrant des données de nouvelles stations d'épuration. Une autre piste pourrait être l'automatisation complète du processus de calibration des caméras, réduisant ainsi la dépendance aux ajustements manuels et augmentant la fiabilité du système.

Chapter 4

Conclusion

Ce rapport se termine en revenant sur les objectifs initiaux fixés au début de ce stage, en examinant dans quelle mesure ceux-ci ont été atteints, et en offrant une réflexion critique sur l'ensemble du travail réalisé. Le projet avait pour but principal de développer une méthode innovante pour le suivi et l'analyse de la qualité de l'eau usée, en utilisant des technologies de pointe telles que l'imagerie multispectrale et les techniques de machine learning.

Tout au long de ce stage, j'ai acquis des compétences techniques essentielles dans le traitement de données complexes, la modélisation prédictive, et l'utilisation d'outils de programmation avancés. Ces compétences m'ont permis non seulement de réaliser les missions qui m'étaient confiées, mais aussi de proposer des améliorations continues tout au long du projet. Le recul que j'ai pris sur ce travail m'a également permis de comprendre l'importance d'une approche méthodique et rigoureuse pour obtenir des résultats fiables et exploitables.

Si c'était à refaire, j'envisagerais d'approfondir davantage certaines étapes du projet, notamment l'optimisation des modèles de machine learning et l'intégration de techniques de validation croisée plus robustes. De plus, j'aurais aimé avoir une connaissance plus approfondie en traitement d'image avant le début du stage, ce qui m'aurait permis de gagner du temps lors de la phase d'implémentation des algorithmes.

Ce stage a renforcé mon intérêt pour le domaine de la data science et de l'analyse environnementale, et m'a permis de mieux comprendre les métiers liés à l'ingénierie des données et à l'analyse prédictive. À court terme, je me vois évoluer dans un poste de data scientist, avec un focus particulier sur les applications environnementales. À moyen terme, je pourrais envisager de me spécialiser davantage en traitement d'image ou en modélisation prédictive avancée.

En conclusion, cette expérience de stage a été extrêmement enrichissante, non seulement d'un point de vue technique, mais aussi en termes de développement professionnel. Elle a marqué une étape clé dans mon parcours, en m'offrant l'opportunité de mettre en pratique les enseignements théoriques de mon Master, tout en me confrontant aux réalités et aux défis du monde professionnel.

Bibliography

- [1] Denys Cuche. *La notion de culture dans les sciences sociales*. 2016.
- [2] Agustsson, J., O. Akermann, D. Barry, and L. Rossi. 2014. ‘Non-Contact Assessment of COD and Turbidity Concentrations in Water Using Diffuse Reflectance UV-Vis Spectroscopy.’ *Environmental Science. Processes & Impacts* 16 8:1897–1902. doi: 10.1039/c3em00707c.
- [3] Caporaso, Nicola, Martin B. Whitworth, and Ian D. Fisk. 2018. ‘Protein Content Prediction in Single Wheat Kernels Using Hyperspectral Imaging’. *Food Chemistry* 240:32–42. doi: 10.1016/j.foodchem.2017.07.048.
- [4] ElMasry, Gamal, Ning Wang, Adel ElSayed, and Michael Ngadi. 2007. ‘Hyperspectral Imaging for Nondestructive Determination of Some Quality Attributes for Strawberry’. *Journal of Food Engineering* 81(1):98–107. doi: 10.1016/j.jfoodeng.2006.10.016.
- [5] EC. Water quality in Europe: effects of the urban wastewater treatment directive: a retrospective and scenario analysis of Dir, 91/271/EEC, LU: Publications Office of the European Union, 2019, [cited 2022 Jun 23], Available from: <https://data.europa.eu/doi/10.2760/303163>.
- [6] F. Blumensaat, P. Staufer, S. Heusch, F. Reußner, M. Schütze, et al. Water quality-based assessment of urban drainage impacts in Europe – where do we stand today?, *Water Sci. Technol.*, 2012, 304–313.
- [7] G. Gruber, J. L. Bertrand-Krajewski, J. D. Beneditis, M. Hochedlinger, and W. Lettl, Practical aspects, experiences and strategies by using UV/VIS sensors for long-term sewer monitoring, *Water Pract. Technol.*, 2006, 1(1), wpt2006020.
- [8] A. Gitelson, R. Stark, and I. Dor, Quantitative near-surface remote sensing of wastewater quality in oxidation ponds and reservoirs: A case study of the Naan system, *Water Environ. Res.*, 1997, 69(7), 1263–1271.
- [9] S. L. Russell, D. R. Marshallsay, B. MacCraith, and M. Devisscher, Non-contact measurement of wastewater polluting load – the Loadmon project, *Water Sci. Technol.*, 2003, 47(2), 79–86.
- [10] Y. Li, X. Wang, Z. Zhao, S. Han, and Z. Liu, Lagoon water quality monitoring based on digital image analysis and machine learning, *Environ. Sci.: Water Res. Technol.*, 2024, 10, 1160.
- [11] P. Lechevallier, *a K. Villez, b C. Felsheimc and J. Rieckermann a, *Environ. Sci.: Water Res. Technol.*, 2024, 10, 1160.

Annexes

Choix des Technologies

Le choix des technologies utilisées dans ce projet s'est basé sur leur capacité à répondre efficacement aux besoins spécifiques du projet, notamment en termes de gestion de données, de collaboration d'équipe, et de traitement d'images. Voici les technologies sélectionnées et une explication de chacune d'entre elles :

Logiciel Colorshadeslab : Colorshadeslab est un logiciel spécialisé dans l'acquisition, l'analyse, et le traitement d'images multispectrales. Dans ce projet, il a été crucial non seulement pour capturer les images à partir des caméras multispectrales, mais aussi pour analyser ces images en détectant et quantifiant les différentes longueurs d'onde présentes dans les données brutes. Ce logiciel a facilité l'extraction des caractéristiques pertinentes des images, ce qui a ensuite permis de développer des modèles prédictifs pour évaluer les niveaux de pollution dans les eaux usées.

Trello : Trello est une plateforme de gestion de projets basée sur des tableaux Kanban. Elle a été utilisée pour organiser, suivre et coordonner les différentes tâches du projet. Trello a permis une collaboration efficace au sein de l'équipe en fournissant une vue claire des étapes du projet, des tâches assignées à chaque membre, et des échéances. Sa flexibilité et son interface intuitive ont facilité la communication et l'organisation tout au long du projet.

Switchdrive : Switchdrive est un service de stockage en ligne sécurisé, comparable à d'autres services de cloud comme Google Drive ou Dropbox. Il a été utilisé pour stocker et partager les données du projet, y compris les images capturées, les résultats intermédiaires, et les documents de travail. Switchdrive a garanti que toutes les données étaient accessibles à l'équipe en temps réel, tout en assurant une protection contre la perte de données grâce à ses fonctionnalités de sauvegarde automatique.

Explication de MLflow

MLflow est une plateforme open-source utilisée pour gérer le cycle de vie des modèles de machine learning. Elle est conçue pour aider les équipes à suivre les expérimentations, à reproduire les résultats, et à déployer facilement des modèles de machine learning dans divers environnements. MLflow propose quatre composants principaux : le suivi des expériences (MLflow Tracking), la gestion des projets (MLflow Projects), la gestion des modèles (MLflow Models), et la gestion des déploiements (MLflow Model Registry).

Intégration de MLflow dans le projet : Au cours de ce projet, MLflow a été intégré pour suivre les différentes expérimentations et les résultats associés. Après l'entraînement de chaque modèle, MLflow enregistre automatiquement les paramètres utilisés, les métriques de performance obtenues, ainsi que les artefacts produits, tels que les modèles eux-mêmes.

Cela permet une comparaison facile entre différentes versions de modèles et assure la reproductibilité des résultats.

L'exécution de MLflow se fait en local, en démarrant l'interface utilisateur de MLflow avec la commande suivante dans le terminal :

```
mlflow ui
```

Cette commande lance un serveur local accessible via <http://localhost:5000>, où toutes les expérimentations peuvent être visualisées, comparées et analysées de manière interactive. Chaque exécution de l'interface MLflow crée un dossier nommé `mlruns` dans le répertoire du projet. Ce dossier contient toutes les informations liées aux expériences, organisées par ID d'exécution, facilitant ainsi la gestion et le suivi des modèles.




Figure 4.1: Illustration du flux de travail avec MLflow

Copyright © 2024 MLflow Project, a Series of LF Projects, LLC. Source : <https://mlflow.org/>

Différence entre caméra multispectrale et hyperspectrale

La principale différence entre les caméras multispectrales et hyperspectrales réside dans le nombre de bandes spectrales qu'elles capturent et dans la gamme de longueurs d'onde qu'elles couvrent.

Les caméras multispectrales capturent des images à travers un nombre limité de bandes spectrales discrètes, généralement entre 3 et 10 bandes. Ces bandes sont sélectionnées pour des applications spécifiques, ce qui signifie que seules certaines longueurs d'onde sont analysées. Les caméras multispectrales sont largement utilisées dans des domaines comme l'agriculture, l'imagerie médicale, et la surveillance environnementale en raison de leur coût relativement bas et de leur capacité à fournir des informations suffisantes pour de nombreuses applications pratiques.

En revanche, les caméras hyperspectrales capturent un spectre continu avec un très grand nombre de bandes (souvent plusieurs centaines). Cela permet une analyse beaucoup plus détaillée et précise des matériaux et des surfaces, car chaque pixel de l'image contient une signature spectrale complète sur une large gamme de longueurs d'onde. Cependant, cette précision accrue a un coût : les caméras hyperspectrales sont généralement beaucoup plus chères et complexes à utiliser que les caméras multispectrales.

Dans ce projet, nous avons choisi d'utiliser des caméras multispectrales en raison de leur coût plus abordable. Bien que la gamme de longueurs d'onde couverte par une caméra multispectrale soit plus restreinte que celle d'une caméra hyperspectrale, elle reste suffisante pour les objectifs de ce projet, notamment l'analyse des indicateurs de pollution dans les eaux usées.




Figure 4.2: Illustration des différences entre imagerie multispectrale et hyperspectrale

Source: ResearchGate. <https://www.researchgate.net/>

Les caméras hyperspectrales offrent une gamme de longueurs d'onde plus large, ce qui permet une détection plus fine et une analyse plus détaillée. Cependant, dans des contextes où le budget est une contrainte, comme c'est le cas dans ce projet, les caméras multispectrales représentent un compromis efficace entre coût et performance.

Types de Caméras Utilisées et Normes Associées

Les caméras utilisées dans ce projet respectent les normes suivantes. Deux caméras multi-spectrales ont été sélectionnées en raison de leur capacité à capturer des données dans des bandes spécifiques de longueurs d'onde, essentielles pour l'analyse de la qualité de l'eau.

Caméra CMS-C

La caméra CMS-C est un dispositif multispectral couvrant la gamme spectrale de 430 à 700 nm. Elle est équipée d'un capteur CMOS avec une monture CS (compatible C-mount avec anneau C supplémentaire). Cette caméra a une résolution d'image brute de 1280 (H) x 1024 (V) pixels et une résolution d'image spectrale de 426 (H) x 339 (V) pixels, avec un pas de pixel de 5.3 μm . Le taux de trame maximal est de 60 Hz, et elle permet des temps d'exposition allant de 10 μs à 2 secondes. Elle utilise un ADC de 10 bits et est contrôlée via une interface USB 3.0. La caméra a des dimensions de 56 x 56 x 22 mm et pèse 100 g.




Figure 4.3: Caméra CMS-C avec spectre de transmission des filtres typiques.

Caméra CMS-S

La caméra CMS-S, quant à elle, couvre la gamme spectrale de 650 à 930 nm. Comme la CMS-C, elle est également équipée d'un capteur CMOS et utilise une monture CS. La résolution brute est la même que pour la CMS-C, mais la résolution des images spectrales varie en fonction de la bande spectrale choisie. Cette caméra offre les mêmes capacités de taux de trame et de temps d'exposition que la CMS-C, avec les mêmes dimensions et poids. Les deux caméras sont configurées en Macropixel 3x3, offrant 8 bandes de couleurs plus une bande noire et blanche pour une analyse précise des images multispectrales.




Figure 4.4: Caméra CMS-S avec spectre de transmission des filtres typiques.

Spécifications Spectrales:

- **Modèle CMS-C** : Plage spectrale de 430-700 nm, largeur de bande moyenne (FWHM) de 40 nm.
- **Modèle CMS-S** : Plage spectrale de 650-930 nm, largeur de bande moyenne (FWHM) de 40 nm.

Caractéristiques Techniques:

- **Type de matrice** : CMOS
- **Interface optique** : Monture CS (compatible C-mount avec anneau C)
- **Résolution (image brute)** : 1280 (H) x 1024 (V)
- **Résolution (images spectrales)** : 426 (H) x 339 (V)
- **Pas de pixel** : 5.3 μm
- **Taux de trame maximal** : 60 Hz
- **Plage de temps d'exposition** : 10 μs à 2 s
- **ADC** : 10 bits
- **Contrôle de la caméra** : USB 3.0
- **Sortie numérique** : USB 3.0
- **Dimensions (L x H x P)** : 56 x 56 x 22 mm
- **Poids (tête de caméra)** : 100 g

Source : SILIOS, © 2024. Site web : <https://www.silios.com/cms-series>.